# 基于 FPGA 的单光纤沿线温升实时报警边缘终端


## 摘要

以 Frontier 为代表的 E 级超级计算机和新建 AI 数据中心大量采用冷板式液冷。现有测点集中在冷却塔、冷水机组和 CDU 等设施级设备上，冷板和支管一级缺少能密集布设的温度测点。电学探头要逐点布线，在高压直流配电环境里还会受电磁干扰；光纤光栅和分布式光纤系统依赖昂贵的解调设备。

本作品是一套面向液冷管路的光纤沿线温升报警系统，由三个子系统协作完成：测温与控温子系统由 STM32、16 路加热片和 13 支探头组成，在管路上制造受控温升并记录真实温度，用于采集数据和标定；光路子系统由激光器、一根沿管路布设的多模光纤和全局快门相机组成，把光纤上的温度变化转成散斑图样的变化；FPGA 边缘节点在一块 Zynq UltraScale+ ZU3EG 板卡上完成散斑采集、推理、报警、显示和 MQTT 上报。

实测发现，即使温度不变，散斑图样也会在几十秒内随激光器状态慢慢改变。为此设计了窗口化报警方法：把 60 s 内的散斑帧平均，比较相隔 120 s 的两个窗口。PL 上的定点卷积网络 QCNN 从两个窗口的图样中学习温升特征，给出 9 路温升估计；同时计算两个窗口的去相关程度，衡量图样的整体变化。前者能学到与位置有关的温升信息，换数据重新训练即可扩展到更多任务，后者不需训练、对漂移稳健，两路融合后按“连续 3 次超限”的规则报警。

在自建测温台的 9 段留出数据上，2 min 内单路升温不少于 1 °C 时检出率 92%，30 次升温事件全部报警，报警延迟中位 25 s。和同一协议下微调的 ResNet-18、MobileNetV3-S 相比，检出率相当，延迟更短，计算量只有它们的 1/8 到 1/270。PL 侧自主实现 MIPI D-PHY 接收、CSI-2 解析、QCNN 推理核和整屏显示合成，推理核在 100 MHz 下稳态每帧 565 μs，输出与定点参考模型逐位一致；板上单帧推理 1.33 ms，比在同一块板的 ARM 核上运行现成网络快 70～2000 倍。


**关键词：**多模光纤散斑；温升报警；FPGA；量化卷积神经网络；液冷监测

# 目　录

摘要 ..... 1
第一部分　作品概述 ..... 3
**1.1 散斑测温原理** ..... 3
**1.2 功能与特性** ..... 3
**1.3 应用领域** ..... 4
**1.4 主要技术特点** ..... 5
**1.5 主要性能指标** ..... 5
**1.6 主要创新点** ..... 5
**1.7 设计流程** ..... 6
第二部分　系统组成及功能说明 ..... 7
**2.1 整体介绍** ..... 7
**2.2 硬件系统介绍** ..... 10
**2.3 软件系统介绍** ..... 12
第三部分　完成情况及性能参数 ..... 16
**3.1 整体介绍** ..... 16
**3.2 工程成果** ..... 16
**3.3 特性成果** ..... 18
第四部分　总结 ..... 23
**4.1 可扩展之处** ..... 23
**4.2 心得体会** ..... 23
**4.3 大模型协作与技能包** ..... 23
**4.4 复现说明** ..... 24
第五部分　参考文献 ..... 25

# 第一部分　作品概述

本报告分五部分。第一部分介绍散斑测温原理、作品功能、应用背景、技术特点、性能指标和设计流程；第二部分介绍系统组成，包括三个子系统的硬件、PL 与 PS 的软硬件划分、报警方法和 QCNN 推理核；第三部分给出实物、PL 资源与时序、报警效果、与其他方法的对比和板上实测结果；第四部分总结可扩展方向、心得体会、大模型协作与复现方法；第五部分为参考文献。

## 1.1 散斑测温原理

激光射入多模光纤后，会分成上百个传播路径不同的“模式”，各自走过不同的光程。到达出射端时，这些模式互相叠加，有的地方加强，有的地方抵消，在屏幕上形成明暗相间的颗粒状图样，称为散斑，如图 1-1 所示。

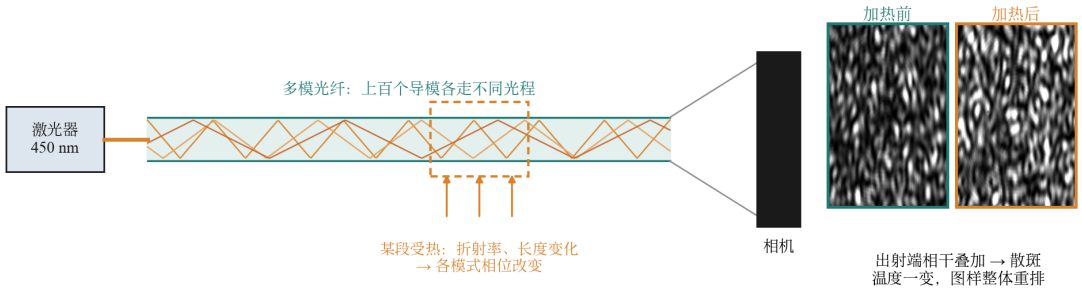



图 1-1　多模光纤散斑测温原理

光纤某一段受热时，玻璃的折射率和光纤长度都会变化，各模式的光程随之改变，叠加结果也就不同，散斑图样整体重排。因此，比较前后两张散斑图的相似程度，就能知道光纤沿线有没有地方在升温。相似度下降越快，温度变化越大。一根光纤上任何一段受热都会反映在同一张图上，所以一根光纤可以监测整段管路。

## 1.2 功能与特性

作品是一台安装在液冷支管旁的报警终端，由一根多模光纤、一台相机和一块 FPGA 开发板组成，主要功能如下。

**沿线温升报警。**光纤沿线任一位置在 2 min 内升温 1 °C 以上时，终端在约半分钟内报警。

**本地显示。**屏幕显示沿线状态、报警得分曲线、实时散斑画面和报警记录，现场可直接查看。

**平台接入。**经 MQTT 向运维平台发布在线状态、每步得分和报警事件，并

接收远程复位指令。

**独立运行。**采集、推理、判断、显示与上报全部在一块板卡上完成，部署时只需光纤、相机和板卡。

光纤不导电、不受电磁干扰，适合高压配电环境；一根光纤覆盖一整段管路，不需要逐点布线。

### 1.3 应用领域

大型算力设施已普遍转向液冷。美国橡树岭国家实验室的 Frontier 是第一台 E 级超级计算机，峰值功耗 29 MW，整机采用 32 °C 温水冷却，两座冷却塔和四台水泵每台每分钟输送约 3.8 万升冷却水[17]。AI 训练进一步推高了用电：国际能源署估计，全球数据中心用电量 2024 年约 415 TWh，到 2030 年将翻倍至约 945 TWh[18]。冷却回路一旦出现冷板堵塞、流量分配不均或局部泄漏，轻则芯片降频，重则停机。管路运维因此成为算力设施的关键问题，能尽早发现局部温升，就能少停机、少浪费电。

作品面向这类液冷系统的末端监测，图 1-2 给出它在冷却链路中的位置。设施级测点集中在一次侧，而热量的源头在二次侧的冷板与支管，这里测点稀疏，局部温升往往要等芯片降频后才被发现。本作品把监测范围下沉到支管和冷板一级，报警经 MQTT 汇入上层运维平台。

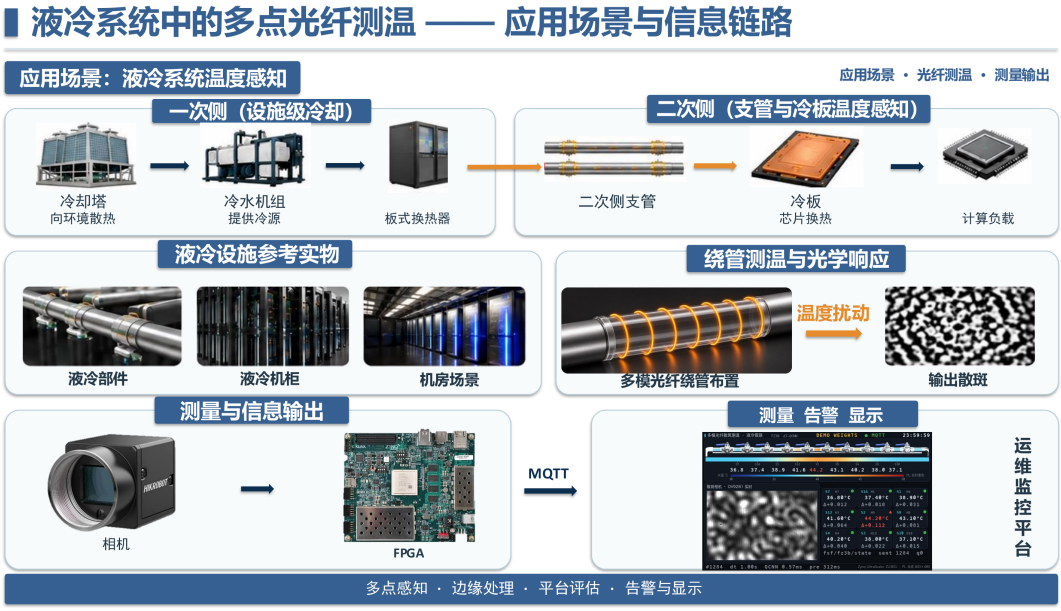



图 1-2　作品在液冷链路中的位置

同一方案也可用于储能电池簇、高压母排和电机绕组等探头难以布设、电磁环境恶劣的场合。

### 1.4 主要技术特点

本节从三个方面说明作品的技术特点。

**（1）系统集成：水路、光路、电路协同。**作品由测温与控温、光路、FPGA 边缘节点三个子系统组成。加热片、探头与光纤在水管上的布置，激光器、光纤与相机的耦合，加热、测温与相机采集的时间对齐，都按统一的接口和时间基准设计，才能得到可重复的实验条件。

**（2）数据与算法：自建测温台、数据集与窗口化报警。**测温台自动控温，同步记录散斑帧、探头温度和加热功率，并录制不加热的对照段。在这些实测数据上发现了激光漂移，据此设计窗口平均、QCNN 与去相关融合的报警方法，门限和融合参数都由对照数据标定。

**（3）FPGA 实现：自主 PL 通路，高性能、低功耗、低资源。**D-PHY 接收、CSI-2 解析、QCNN 推理核与显示合成均为自主编写的 RTL。推理核层内按输出通道并行，层间以帧为单位流水，中间特征图不经 DDR，用 30% 的 DSP 和约 0.3 mJ 的单次能耗完成实时推理。

### 1.5 主要性能指标

表 1-1　主要性能指标

| 指标 | 数值 | 条件 |
|---|---|---|
| 温升检出率 | 92%（≥1 °C/2 min） | 对照误报 1%，9 段留出数据 |
| 升温事件检出 | 30/30 | 单路设定上调 ≥2 °C |
| 报警延迟 | 中位 25 s | 升温开始到报警 |
| 散斑采集帧率 | 149.8 fps | 640×800 RAW8，板上实测 |
| 推理吞吐 | 565 μs/帧 | 100 MHz，RTL 仿真 |
| 板上单帧推理 | 1.33 ms | 含 DMA 往返，板上实测 |
| PL 资源 | LUT 28.8%　DSP 30.0%　BRAM 24.8% | 合并比特流，布线后 |
| 片上功耗 | 2.99 W | Vivado 估计 |
| 显示输出 | 800×480 @ 60 Hz | Mini DP，7 英寸屏 |

### 1.6 主要创新点

① 用一根多模光纤的散斑实现整段管路的温升报警，替代逐点布设的探头。

② 针对实测的激光漂移，提出窗口平均、QCNN 与去相关融合、规则判定三步组成的报警方法，门限只依赖不加热的对照数据。

③ 自主实现的 FPGA 散斑处理流水线，采集、推理与显示合成在 PL 完成，推理层间数据不经 DDR。

④ 感知、报警、显示与平台上报在单块板卡上闭环。

## 1.7 设计流程

设计流程如图 1-3 所示，分为测温台与数据、算法与模型、FPGA 实现三条主线。测温台主线搭建水路、光路和电路，按设定序列录制加热段与不加热的对照段；算法主线在这些数据上设计窗口化报警方法，完成量化训练，并导出定点参考模型；FPGA 主线完成 RTL 设计、逐位比对仿真、Vivado 实现和上板测试。定点参考模型是后两条主线的接口，上板实测结果再反馈到采集方案和报警方法。

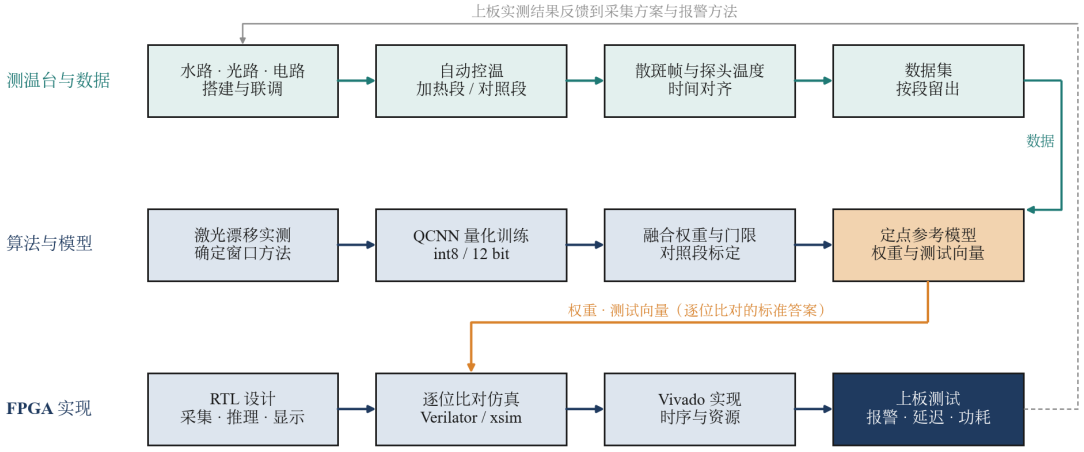



图 1-3　设计流程

# 第二部分　系统组成及功能说明

## 2.1 整体介绍

### 2.1.1 系统组成

系统由测温与控温、光路、FPGA 边缘节点三个子系统组成，如图 2-1 所示。测温与控温子系统以 STM32 为主控，驱动 16 路加热片在光纤上制造受控温升，并以 13 支数字探头记录真实温度；光路子系统由激光器、多模光纤与全局快门相机组成，把光纤上的温度变化转成散斑图样的变化；FPGA 边缘节点完成采集、推理、报警、显示与上报。测温台只在采集训练与评估数据时使用，部署时节点只需要光纤和相机。

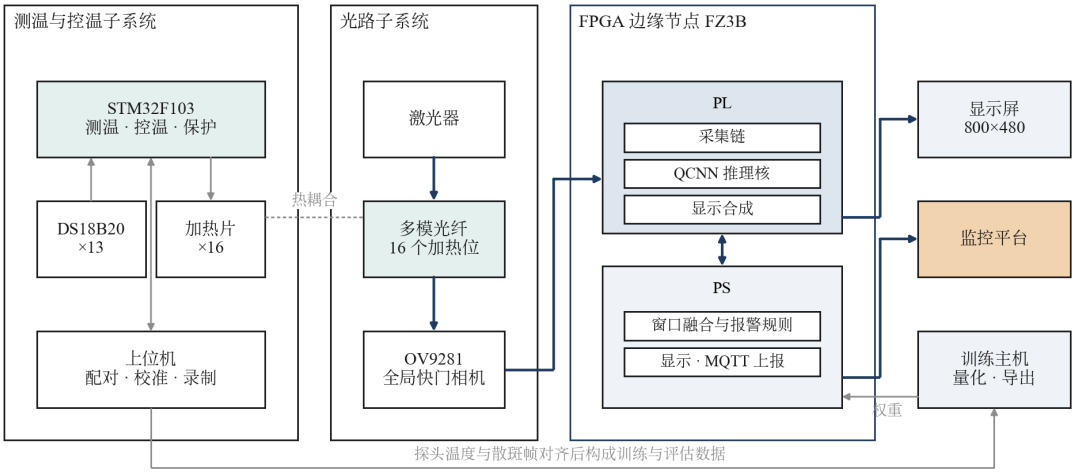
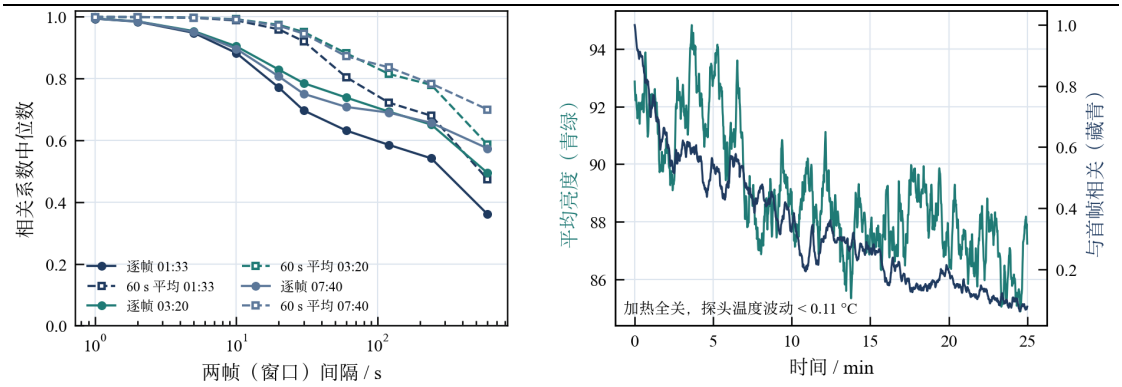



图 2-1　系统组成

### 2.1.2 散斑传感原理与漂移

激光在多模光纤中激发大量导模，各模式相位不同，在出射端面相干叠加形成散斑。温度通过热光效应和热膨胀改变各模式相位，散斑随之重排，变化程度可用两帧之间的相关系数度量。

图 2-2 是加热全关时的实测结果。两帧相隔 60 s，相关系数已降到 0.6～0.7，而探头温度几乎不变。这一漂移来自激光器的波长与功率起伏，在几十秒内来回摆动，几小时后的图样也不会回到原来的状态。因此，单帧图样无法对应到固定的温度。把 60 s 的帧平均后再比较，同样间隔下的相关系数明显回升，说明平均能抵消大部分漂移。本作品的报警方法即建立在这一实测规律上。




(a) 恒温下相关系数随间隔下降　　(b) 一段 25 min 恒温记录

图 2-2　恒温条件下的散斑漂移

### 2.1.3 数据流

FZ3B 上的数据流如图 2-3 所示，按编号依次为：

① 采集。OV9281 输出 MIPI CSI-2 数据，PL 中的 D-PHY 接收与 CSI-2 解析模块恢复像素流，经打包与跨时钟域 FIFO 后由 VDMA 写入 DDR4。

② 预处理。PS 读取最新一帧，完成行合并、平场校正与标准化，并累入 60 s 滑动窗口。

③ 推理。AXI DMA 把两个窗口的平均图样（56×56）送入 QCNN 推理核，各层特征图保存在本层输出 RAM 中。

④ 判断。9 路温升估计经 DMA 写回 DDR4，PS 把它与窗口去相关得分融合，按报警规则判定。

⑤ 显示。PS 更新屏幕状态，PL 读取 DDR 中的背景与相机帧，逐像素合成 800×480 画面，经 DPSUB 实时视频层输出。

⑥ 上报。PS 通过以太网以 MQTT 协议发布状态与报警。

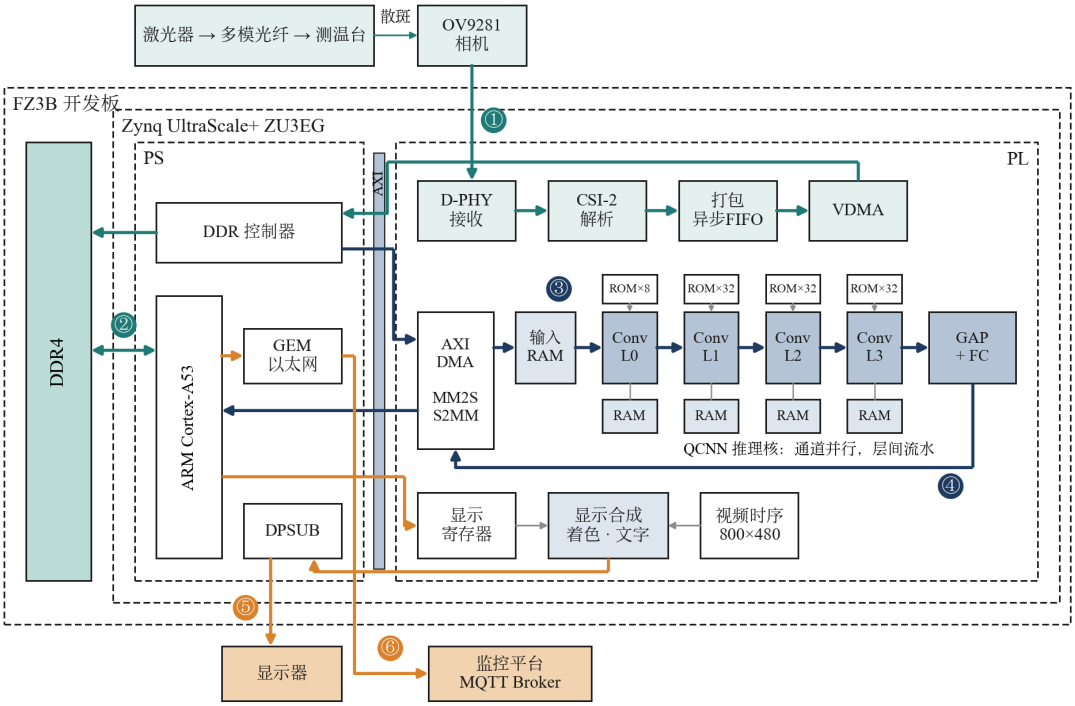



图 2-3　数据流

### 2.1.4 报警方法

报警方法如图 2-4 所示，分三步。

**窗口平均。**每 5 s 取一次最近 60 s 的平均图样作为窗口 B，与 120 s 前的平均图样（窗口 A）比较。120 s 的间隔让光纤有时间升温，60 s 的平均抵消大部分激光漂移。

**两路得分。**QCNN 在 PL 上运行，输入两个窗口的 56×56 平均图样，输出 9 路温升幅度，取最大值；PS 同时把两个窗口降到 10×16 块，计算 1 减相关系数。两路得分各自按不加热对照数据的均值和标准差标准化，加权相加得到报警得分。

**为什么用两路。**窗口去相关不需要训练，只衡量图样整体变了多少，对激光漂移稳健，但它分不出变化来自哪里、也无法从数据中改进。QCNN 能从两个窗口的图样中学到与温升有关的空间特征，输出按测点分开的 9 路估计，数据越多、标注越细，能力越强；同一个推理核换一套权重，就能用于按点位报警、绝对温度估计、泄漏或脏堵检测等任务，硬件不用改。两路互补：去相关保证在漂移下的稳健性，QCNN 提供可学习、可扩展的部分。

**报警规则。**得分连续 3 次超过门限即报警，报警后冷却 300 s 再允许下一次。门限取对照数据得分的 99.5% 分位。整个方法只有门限一个参数需要从对照数据确定，换一根光纤或换一个场地，录一段不加热的数据即可重新标定。

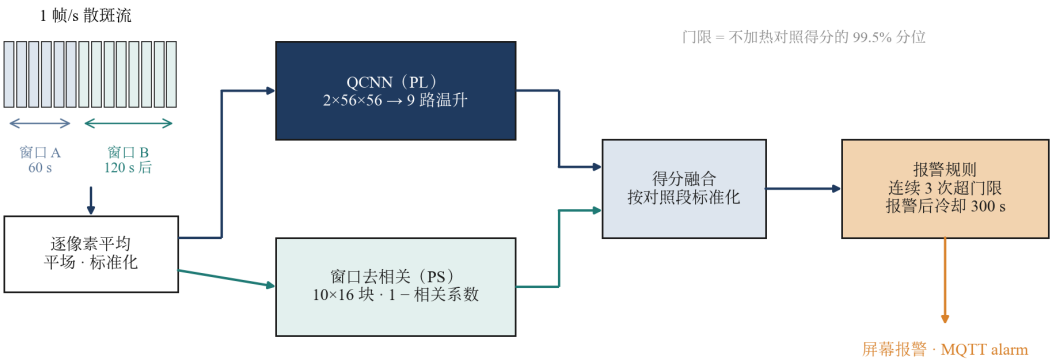



图 2-4　报警方法

### 2.1.5 QCNN 推理核

网络结构如图 2-5 所示。输入为 2×56×56 的两个窗口平均图样，经四层 3×3、步长 2 的卷积降到 64×4×4，再经全局平均池化与两层全连接输出 9 路温升幅度。网络共 6.2 万个参数，单次推理 2.6 MMAC。权重为 int8，激活为 12 bit 无符号数，层间以移位方式重新量化，全程整数运算。

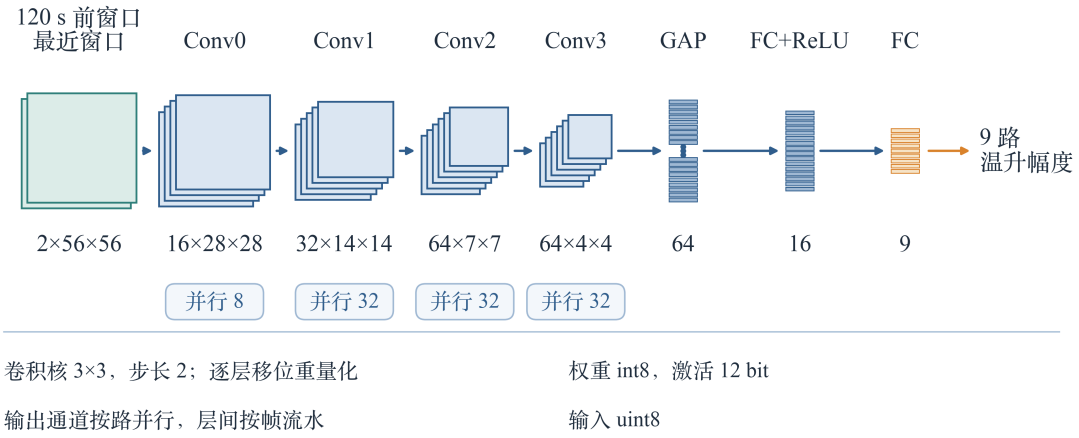



图 2-5　QCNN 网络结构

卷积层内，一个输入激活同时送往 PAR 路乘法器，每路持有本组输出通道的权重 ROM，一次读取驱动 PAR 次乘加；四层的并行度分别为 8、32、32、32。各层拥有独立的输出 RAM，层间以握手传递帧，多帧可同时处于不同层中。100 MHz 下推理核稳态每帧 565 µs，首帧延迟 1.12 ms；以训练好的权重和 16 组实测窗口对仿真，144 个输出与定点参考模型逐位一致。

## 2.2 硬件系统介绍

### 2.2.1 硬件整体介绍

硬件由测温台、光路与 FPGA 节点三部分组成，连接关系如图 2-6 所示。测温台的控制箱经 USB 串口与上位机通信，16 路加热片与 13 支探头沿光纤

布置；光纤出射端正对相机，相机经转接板以 MIPI 接入 FZ3B；FZ3B 经千兆网口接入交换机，经 Mini DP 驱动 7 英寸 800×480 显示屏。主要器件见表 2-1。

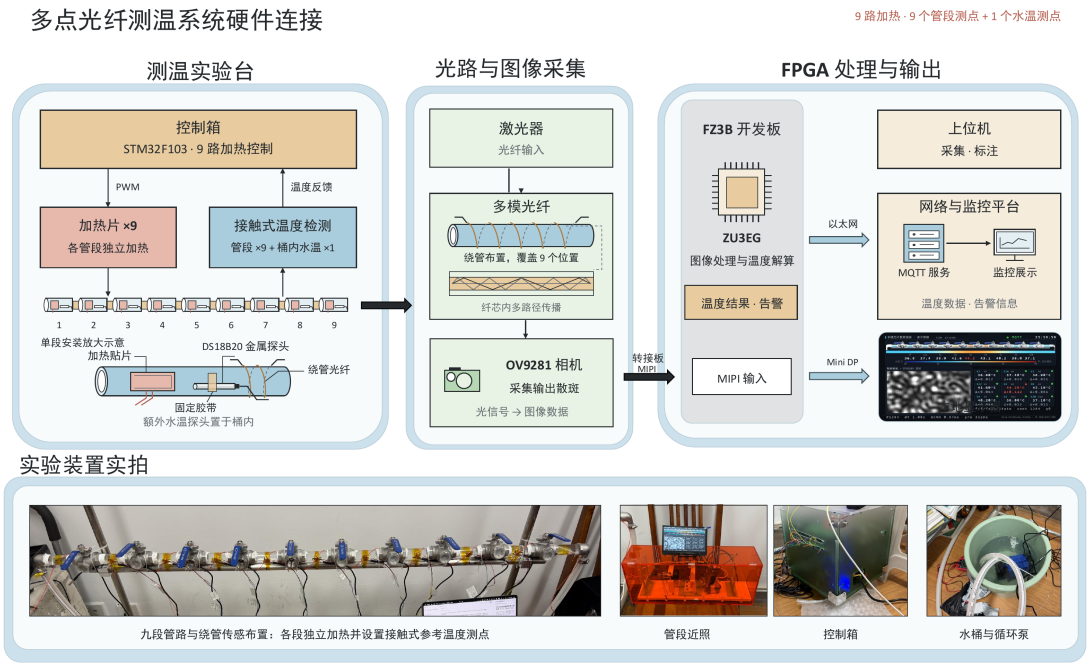



图 2-6　硬件连接

表 2-1　主要器件

| 模块 | 型号与规格 | 数量 | 作用 |
|---|---|---|---|
| FPGA 平台 | EdgeBoard FZ3B，ZU3EG，DDR4 4 GB | 1 | 采集、推理、显示、通信 |
| 相机 | OV9281，1280×800，全局快门，RAW8 | 1 | 散斑采集 |
| 光源 | 450 nm 半导体激光器 | 1 | 照明 |
| 光纤 | 通用多模光纤，3 m | 1 | 传感 |
| 测温主控 | STM32F103C8T6，72 MHz | 1 | 测温、控温、保护 |
| 测温探头 | DS18B20，12 bit | 13 | 真实温度记录 |
| 加热 | 硅胶加热片 12 V / 5 W，MOS 低侧开关 | 16 | 受控加热 |
| 显示屏 | 7 英寸 800×480，Mini DP | 1 | 本地显示 |

### 2.2.2 机械设计介绍

控制电路、电源与接线端子收纳在 250 mm 立方的亚克力箱体内，箱体用 5 mm 亚克力激光切割，四面墙板等尺寸搭接，前墙与侧墙开长槽分别引出加热导线与探头导线。光纤段用导热胶贴在各加热位上，加热片与探头分置光纤两侧，使探头读数代表光纤所在位置的温度。相机与光纤出射端固定在同一底板上，外

加遮光罩，减少杂散光与机械扰动。

### 2.2.3 电路各模块介绍

**测温通道。**每支 DS18B20 独占一个 GPIO。单支探头断线或短路只影响本通道，故障可直接定位到引脚；13 支探头同时启动转换，750 ms 后依次读取。

**加热通道。**三片 74HC595 级联，用 3 根信号线扩展出 16 路控制，分别驱动 16 个 MOS 模块。595 输出使能脚上拉、MOS 栅极下拉，复位或程序未运行时全部加热片关断。12 V 加热回路与逻辑回路分开走线，单点共地。

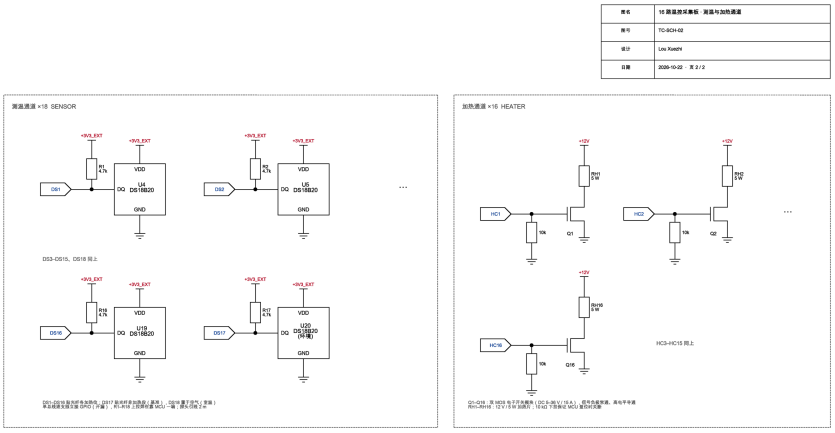


图 2-7　测温通道与加热通道原理图

**相机接口。**OV9281 的 MIPI 时钟与数据线经转接板接入 FZ3B 的 HP Bank 64，PL 用 IBUFDS_DPHY 原语直接接收差分信号，不依赖 MIPI D-PHY 硬核 IP。表 2-2 为 PL 的引脚分配。

表 2-2　PL 引脚分配

| 信号 | 引脚 | 电平标准 | 说明 |
|---|---|---|---|
| MIPI CLK P / N | AD5 / AD4 | MIPI_DPHY_DCI | 800 Mb/s 位时钟 |
| MIPI D0 P / N | AC4 / AC3 | MIPI_DPHY_DCI | 数据 lane 0 |
| MIPI D1 P / N | AB4 / AB3 | MIPI_DPHY_DCI | 数据 lane 1 |
| cam_mclk | L7 | LVCMOS18 | 相机主时钟 24 MHz |
| cam_rst_n / cam_pwdn_n | U9 / Y8 | LVCMOS18 | 相机复位与掉电 |
| pl_ref_clk | D4 | LVCMOS18 | 25 MHz 参考时钟 |

## 2.3 软件系统介绍

### 2.3.1 软件整体介绍与软硬件划分

软件分为 PL 逻辑、PS 节点程序、测温台固件与离线工具四层，见表 2-3。PL 与 PS 之间通过 AXI4-Lite 寄存器与 AXI DMA 交互。

表 2-3　软件组成

| 层次 | 模块 | 实现 | 功能 |
|---|---|---|---|
| PL | 采集链 | Verilog | D-PHY 接收、CSI-2 解析、VDMA 写帧 |
| PL | QCNN 推理核 | Verilog | 2×56×56 → 9 路温升定点推理 |
| PL | 显示合成 | Verilog | 背景、着色、相机画面、文字叠加 |
| PS | 节点程序 | Python | 预处理、窗口、DMA 调度、融合、报警、MQTT |
| 测温台 | 固件 | C / HAL | 1 s 节拍测温、PID 控温、多级保护 |
| 离线 | 训练与导出 | Python | 量化训练、定点参考模型、权重与测试向量 |

软硬件划分按三条原则确定。第一，数据量大、节拍固定的部分放 PL：MIPI 解串必须在 PL 完成，每帧 51 万像素的显示合成在 PS 上做不到 60 Hz。第二，运算密集且结构规整的部分放 PL：QCNN 一次推理 2.6 MMAC，同一网络在 A53 上用定点实现要 33.5 ms，在 PL 上 1.33 ms。第三，逻辑分支多、需要网络协议栈的部分放 PS：报警规则、MQTT 与远程指令都在 PS。窗口去相关只有 160 维，PS 上每次不到 1 ms，没有必要占用 PL。

### 2.3.2 软件各模块介绍

**（1）采集链。**链路结构如图 2-8 所示。时钟 lane 经 IBUFDS_DPHY 与 BUFGCE_DIV 产生位时钟和四分频字节时钟；数据 lane 经 IDELAYE3 调整采样相位，ISERDESE3 完成 1:8 解串。每个 lane 有独立的 LP 状态机，在 HS 突发起始处搜索同步字 0xB8，同时检查正反两种极性，板级 P/N 交换不需要改约束。CSI-2 解析模块校验包头 ECC 与载荷 CRC，任何一项校验失败即丢弃到 EoT。像素经 16→64 位打包与异步 FIFO 跨入 AXI 时钟域，由 VDMA 以四帧存方式循环写入 DDR4。

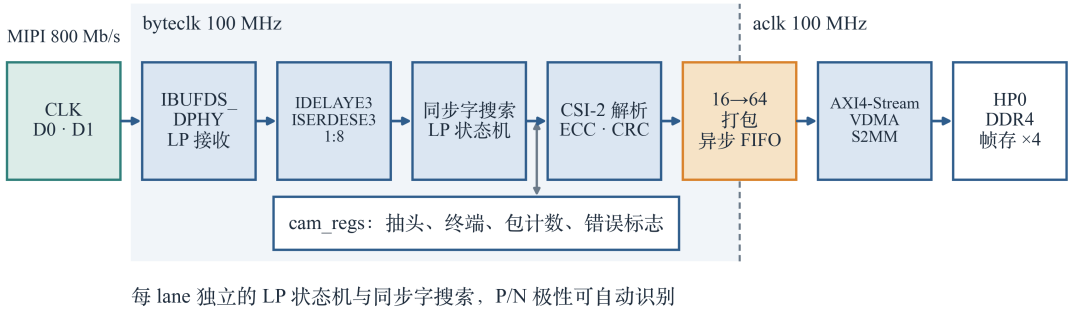



图 2-8　PL 采集链

**（2）卷积层。**单层数据通路如图 2-9 所示，按 S0 到 S4 五级流水运行。S0 依次遍历输出坐标、输出通道组与卷积抽头，S1 生成源特征图地址，S2 读

出一个输入激活并同时送入 PAR 路乘法器，S3 累加，S4 按层移位量重新量化并钳位到 12 bit。层与层之间以 valid / taken 握手：本层写完一帧后置 dst_valid，下一层读走后释放，本层随即开始下一帧。

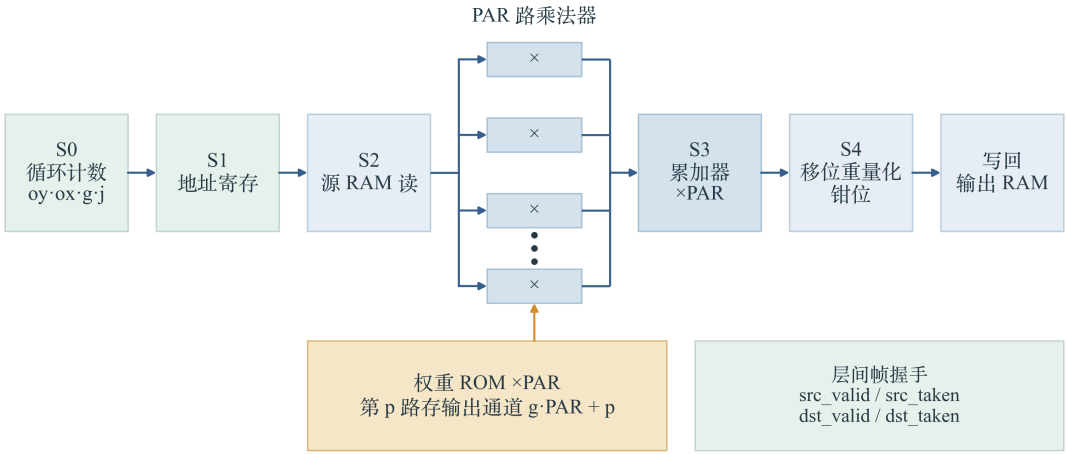



图 2-9　卷积层数据通路

**（3）定点方案。**训练分浮点预训练、激活范围校准和量化感知训练三步。权重量化为 int8，激活为 12 bit 无符号数，偏置为 int32。每层的缩放因子取 2 的整数次幂，重新量化只需算术右移。定点参考模型 qcnn_int.py 与 RTL 用同一套移位与舍入规则，导出 .mem 权重文件、参数头文件与测试向量。训练时随机交换两个窗口的顺序并做小幅平移，让网络对图样整体位置和比较方向不敏感。

**（4）显示合成与界面。**PL 逐像素合成 800×480 画面：静态背景预先渲染后放在 DDR，PL 按行读取背景与相机帧存，动态数字由 12×24 字模 ROM 叠加，暂存寄存器在场消隐期统一生效，画面无撕裂。PS 触屏界面提供总览、散斑视图和报警记录等页面，图 2-10 为总览页与报警页。




图 2-10　终端界面：(a) 总览　(b) 报警

**（5）节点程序。**程序流程如图 2-11 所示。采集线程只保留最新一帧；主循环每个周期取出该帧，完成平场与标准化后并入滑动窗口，每 5 s 经一次 DMA 调用得到 QCNN 温升估计，与窗口去相关融合后按规则判定。报警状态变化时以 QoS 1 发布。MQTT 收发在独立线程中进行，队列有界，Broker 断开

不阻塞推理与显示。

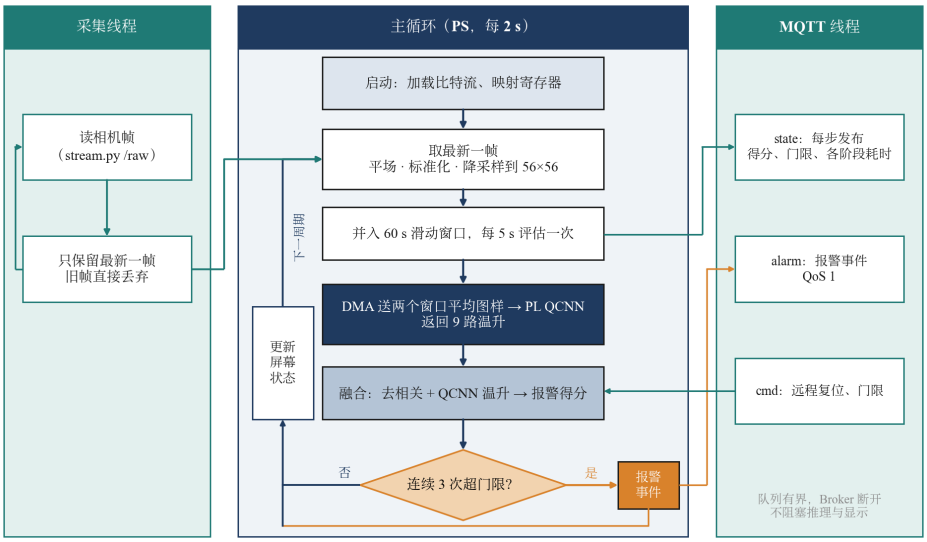



图 2-11　节点程序流程

**（6）MQTT 主题。**节点以 fsf/<节点名>/ 为前缀发布与订阅，见表 2-4。

表 2-4　MQTT 主题

| 主题 | 方向 | QoS | 内容 |
|---|---|---|---|
| status | 发布 | 1，保留 | 在线状态；遗嘱消息为 offline |
| state | 发布 | 0 | 每步报警得分、门限、各阶段耗时 |
| alarm | 发布 | 1 | 报警事件：时刻、得分、门限 |
| cmd | 订阅 | 0 | 远程复位、门限调整 |

**（7）测温台固件与数据采集。**固件以 1 s 为周期：13 支探头同时启动转换，800 ms 后读回并完成每路 PID 计算，随后发出一帧带校验的 ASCII 数据。加热输出采用时间比例方式，2 s 窗口、1 % 分辨率。固件具备探头失效、过温跳闸、上位机失联与看门狗四级保护，复位后全部加热关断。采集时相机锁定曝光，每秒取 5 帧做逐像素中位数，以 1 帧/s 记录散斑、13 路温度和 16 路占空比。

# 第三部分　完成情况及性能参数

## 3.1 整体介绍

图 3-1 为测温实验台的九段管路，光纤绕管布置，各段独立加热；图 3-2 为水桶、循环泵与光路箱，触摸屏放在光路箱上方。

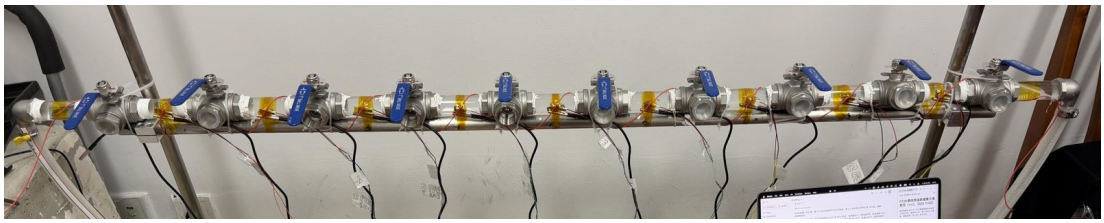


图 3-1　九段管路与绕管光纤，各段独立加热



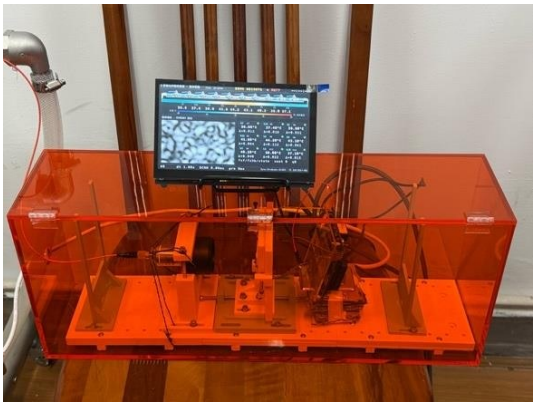


图 3-2　(a) 水桶与循环泵　(b) 光路箱与屏幕

## 3.2 工程成果

### 3.2.1 机械成果

控制箱为 250 mm 立方的亚克力箱体；光路暗箱用橙色亚克力遮挡环境光，内部固定光纤出射端与相机。



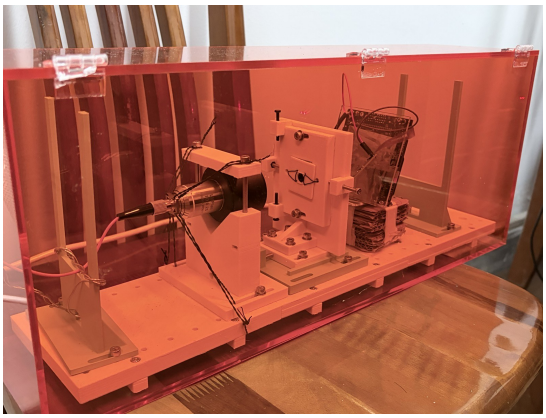


图 3-3　(a) 控制箱　(b) 遮光暗箱：光纤出射端正对相机

### 3.2.2 电路成果

测温主控板在洞洞板上焊接，STM32 核心板、74HC595 与 MOS 模块按图 2-7 连接；光源为 450 nm 半导体激光器，带电流显示。

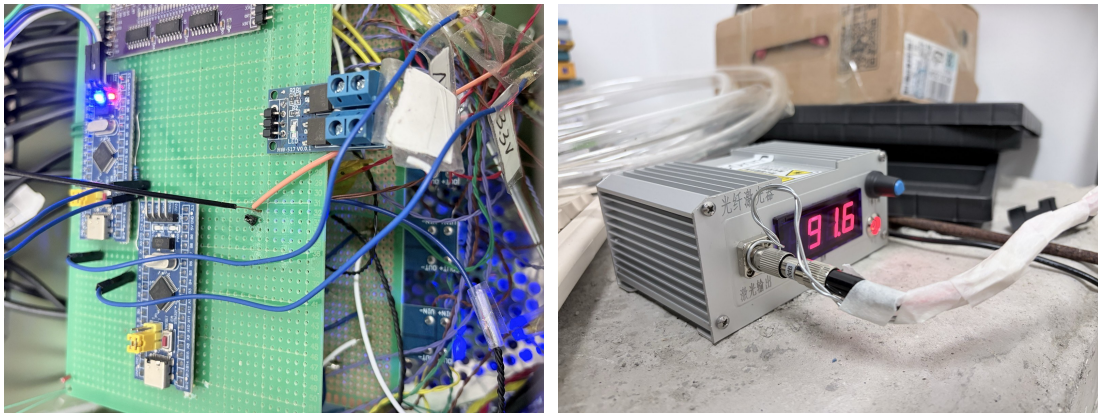


图 3-4 (a) 测温主控板 (b) 450 nm 半导体激光器

FPGA 节点为 EdgeBoard FZ3B（图 3-5），板上带散热风扇和千兆网口；OV9281 相机经自制转接板以 MIPI 接入板卡的扩展接口。

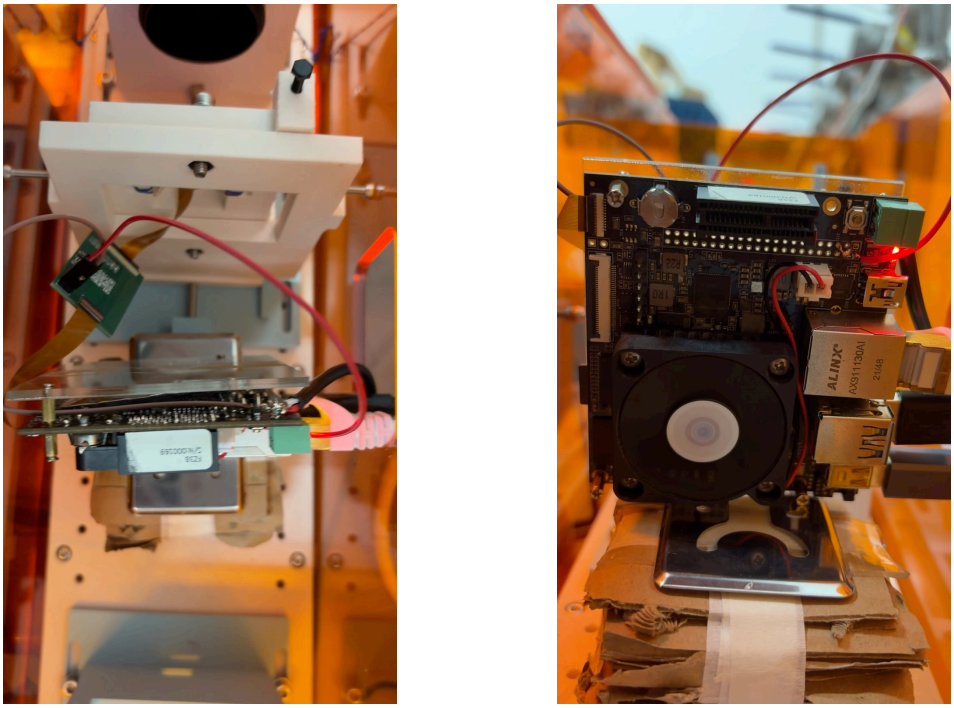


图 3-5 FZ3B 板卡与相机转接

### 3.2.3 软件成果

图 3-6 为 7 英寸触摸屏实拍：总览页显示管路沿线读数、光纤报警状态、实时散斑和各测点曲线。




图 3-6　终端屏幕实拍

PL 设计用 Vivado 2026.1 在 xczu3eg-sfvc784-1-i 上完成综合与实现，采集链、推理核（已载入训练权重）与显示合成合并为一个比特流，全部时钟域时序收敛。资源与时序见表 3-1。

表 3-1　PL 资源与时序

| 项目 | 用量 | 占比 | 说明 |
|---|---|---|---|
| LUT | 20322 | 28.8% | 全设计 |
| FF | 20041 | 14.2% | |
| BRAM | 53.5 | 24.8% | 特征图与权重全部片上 |
| DSP | 108 | 30.0% | 推理核 104 |
| clk_pl_0 100 MHz | WNS +2.55 ns | | AXI、DMA、推理核 |
| vclk 74.25 MHz | WNS +8.26 ns | | 显示像素时钟 |
| 片上功耗 | 2.99 W | | Vivado 估计 |

## 3.3 特性成果

### 3.3.1 数据集

测温台共录制 37 段数据，约 9.5 万帧，时间线如图 3-7 所示。第三次采集针对激光漂移重新设计：相机锁定曝光，每秒 5 帧取中位数，并加入 4 段全程不加热的纯对照和 5 段每档保持 8～10 min 的长平台。报警方法的训练与评估使用第三次采集的 11 段数据，共 3.4 万帧。

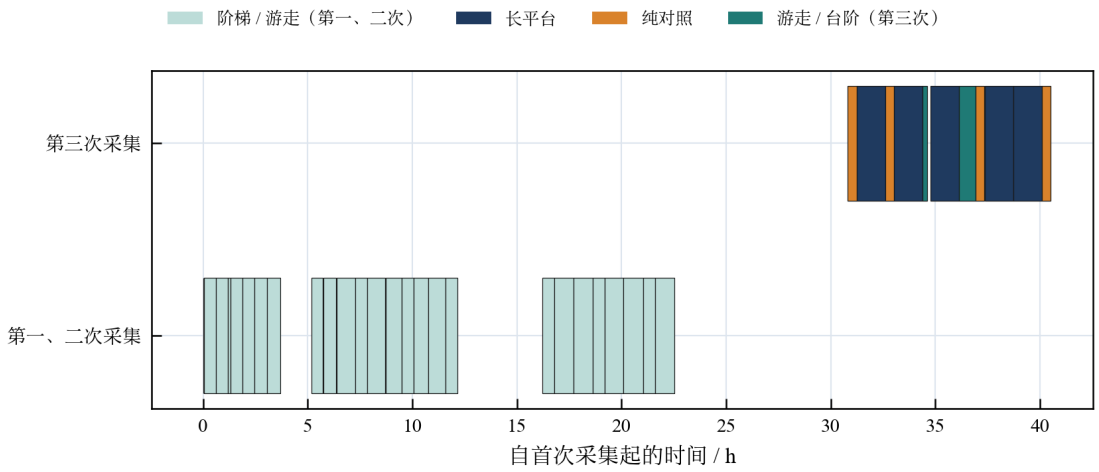



图 3-7　数据集时间线

评估采用留出方式：每次留出 1 段长平台和 1 段对照，其余数据训练 QCNN、确定融合权重和门限，共 5 折，每段长平台都当过一次测试集。标签取探头在两个窗口内的平均温差，对照段的标签为 0。探头比光纤慢 15～45 s，小温升档的检出率会因此偏低。

### 3.3.2 报警效果

图 3-8 是一段 80 min 长平台的报警过程。上图是加热各路的探头温度，下图是报警得分。每次设定上调后，得分在半分钟左右越过门限并报警；温度保持不变后，得分回落到门限以下。

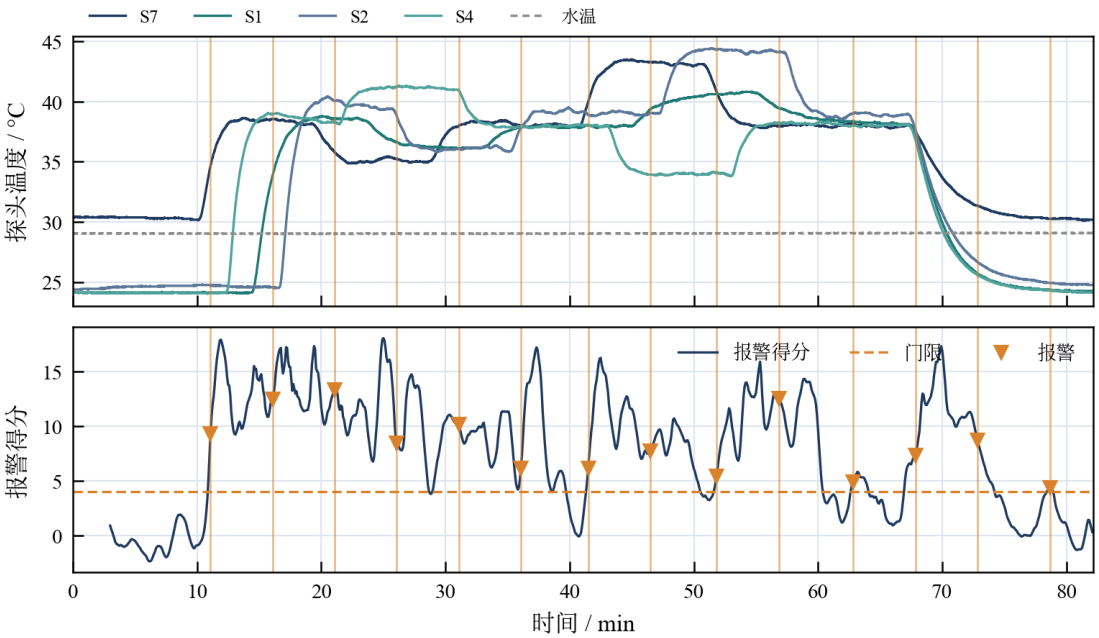



图 3-8　一段长平台的报警过程（留出数据）

图 3-9(a) 按 2 min 内单路最大温升分档统计检出率。温升不小于 2 °C 时检出 97%，1～2 °C 时 83%，0.25 °C 以下只有 6%，与对照段的误报水平相当。

图 3-9(b) 是 30 次升温事件的报警延迟，中位 25 s，90% 的事件在 235 s 内报警。4 段对照共 1.5 h，报警规则下误报 4 次，全部出现在同一段对照里，其余 3 段为 0 次。

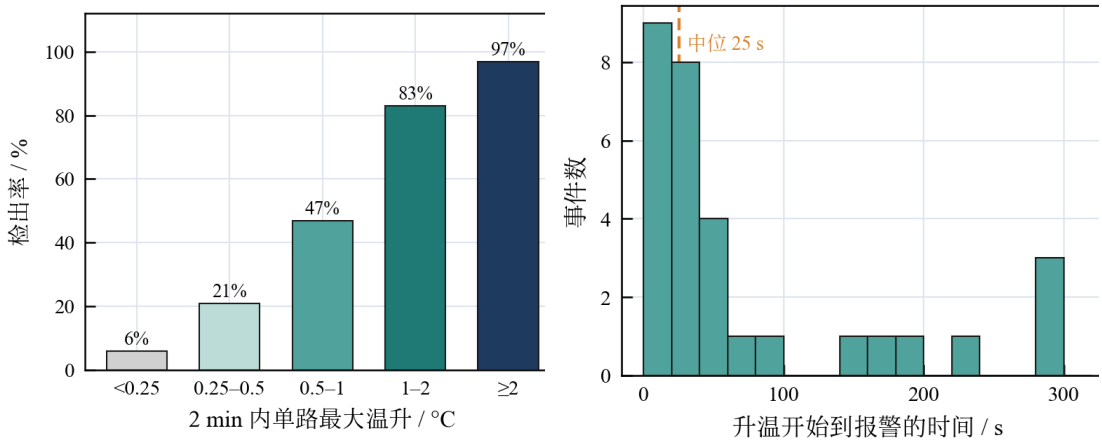



图 3-9 (a) 检出率随温升幅度 (b) 报警延迟

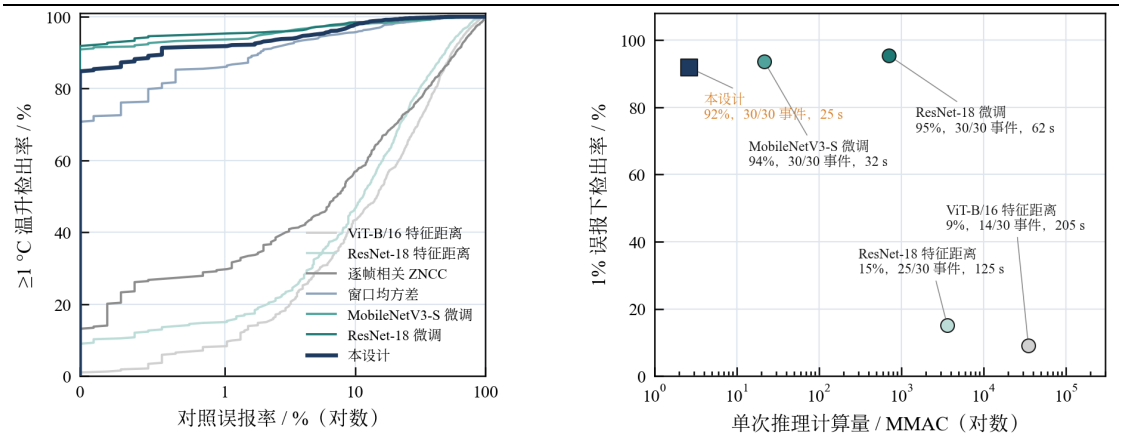
### 3.3.3 与其他方法对比

所有方法使用相同的窗口、相同的 5 折划分、相同的报警规则，门限都只用训练折的对照数据确定，结果见表 3-2 和图 3-10。对比对象包括：经典的逐帧散斑相关、窗口均方差、ImageNet 预训练的 ResNet-18 和 ViT-B/16 特征距离，以及在同样数据上微调的 ResNet-18 和 MobileNetV3-S。

表 3-2 同一协议下的报警方法对比

| 方法 | AUC | 检出率 | 事件检出 | 延迟中位 | 计算量 / MMAC |
|---|---|---|---|---|---|
| 本设计 | 0.993 | 92% | 30/30 | 25 s | 2.6 |
| ResNet-18 微调 | 0.994 | 95% | 30/30 | 63 s | 712 |
| MobileNetV3-S 微调 | 0.992 | 94% | 30/30 | 33 s | 22 |
| 窗口均方差 | 0.986 | 86% | 30/30 | 25 s | — |
| 逐帧相关 | 0.816 | 30% | 24/30 | 213 s | — |
| ResNet-18 特征距离 | 0.817 | 15% | 25/30 | 125 s | 3628 |
| ViT-B/16 特征距离 | 0.777 | 9% | 14/30 | 205 s | 35126 |

AUC 与检出率针对 2 min 内单路升温不少于 1 °C 的窗口，检出率在 1% 误报下统计。不做时间平均的逐帧相关只能检出 30%，直接套用预训练网络的特征更差，说明漂移是这一任务的主要难点。本设计的检出率与微调后的 ResNet-18 相当，报警延迟短一半，计算量为其 1/270；与 MobileNetV3-S 相比，检出率相当，计算量为其 1/8。只有本设计的网络能在 PL 上实时运行，其余深度网络在板上 ARM 核上单帧需要 0.1～2.7 s。




(a) ROC　　(b) 检出率与计算量

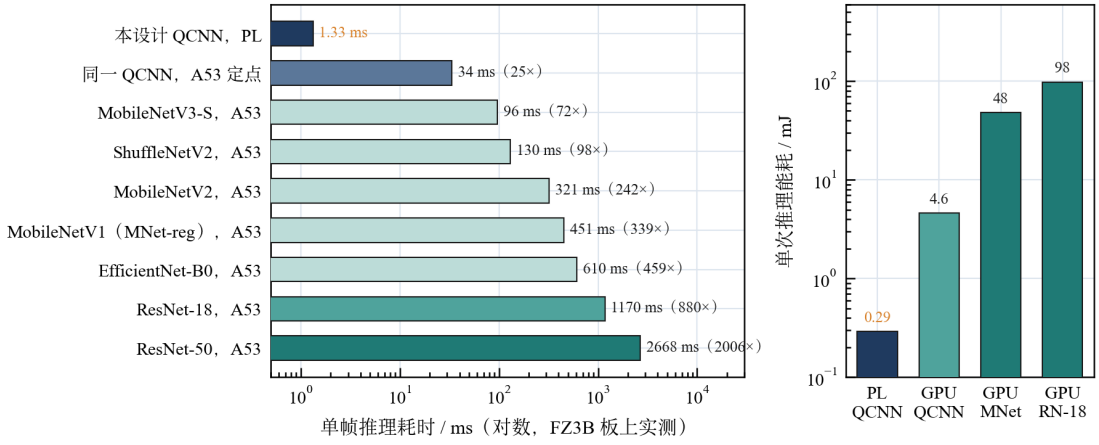
图 3-10　报警方法对比

### 3.3.4 散斑采集

采集链在板上连续运行，1280×800 模式下得到 640×800 图像 149.8 帧/s，640×400 合并模式下得到 320×400 图像 299.0 帧/s，10 s 内每帧行数完整、无坏包头、VDMA 无错误。

### 3.3.5 板上推理与优化效果

在 FZ3B 上分别测量 PL 推理核和 A53 上的软件实现，结果如图 3-11 所示。PL 单帧 1.33 ms，包含 Python 写缓冲、启动 DMA 与逐字读回；每批 16 帧时平均每帧 0.64 ms。载入训练权重后，板上 40 组输入（16 组实测窗口、24 组随机）的输出与定点参考模型逐位一致，单帧 1.34 ms。同一 QCNN 在 A53 上用定点实现要 33.5 ms，PL 快 25 倍；能部署到板上的现成网络在 A53 上需要 96～2668 ms，PL 快 70～2000 倍。按 Vivado 估计的推理核功耗乘实测延迟，PL 单次推理约 0.29 mJ，台式机 GPU 运行 MNet-reg 为 48 mJ。




(a) 板上单帧推理耗时　　(b) 单次推理能耗

图 3-11　板上推理耗时与能耗

推理核的结构经过两轮优化，见表 3-3 和图 3-12。初版每层只用 1 个乘法

器，单帧 18.06 ms；改为按输出通道并行、层间流水后降到 0.565 ms，DSP 由 7 个增加到 104 个。同一模型用 hls4ml 生成的实现在 XC7Z020 上 BRAM 需求为器件容量的 2～4 倍，无法布局。本设计在同一器件上 BRAM 占用 21%，时序收敛。

表 3-3　推理核优化前后对比（XC7Z020，同一模型）

| 实现 | 单帧延迟 | DSP | BRAM_18K | 能否布局 |
|---|---|---|---|---|
| 串行实现（优化前） | 18.06 ms | 7 | — | 能 |
| 本设计（并行 + 流水） | 0.565 ms | 104 / 220 | 60 / 280 | 能 |
| hls4ml，复用因子 576 | 5.36 ms | 106 / 220 | 603 / 280 | 超出容量 |
| hls4ml，复用因子 64 | 2.70 ms | 915 / 220 | 1080 / 280 | 超出容量 |

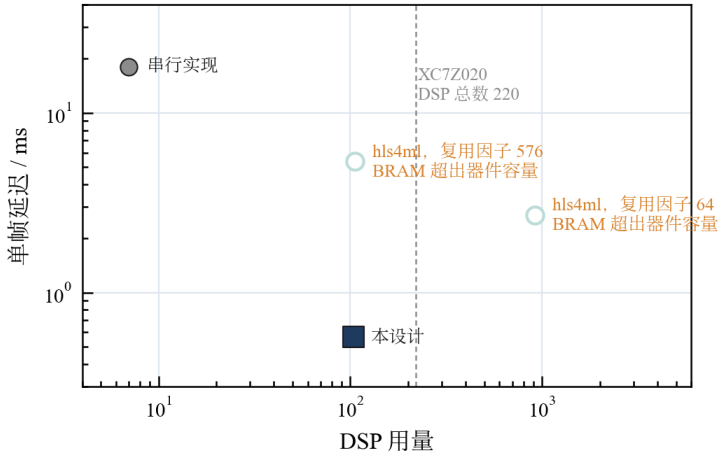
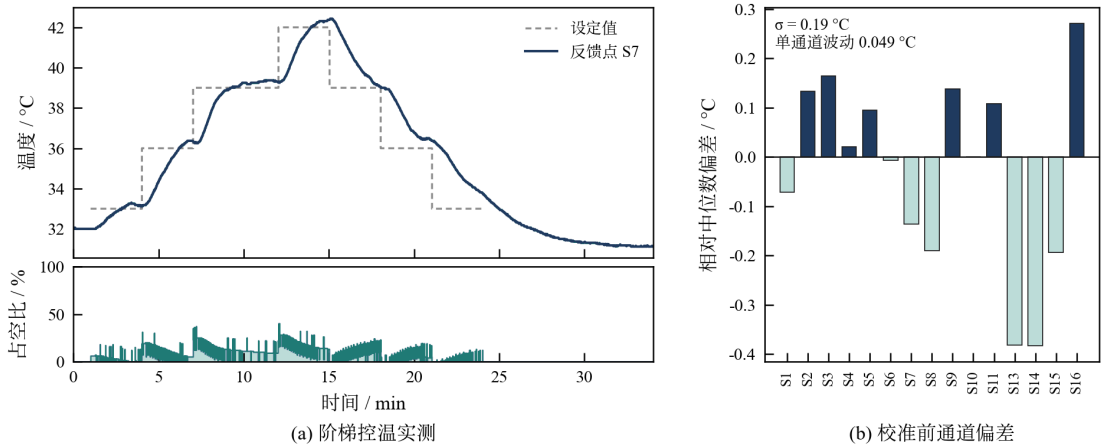



图 3-12　PL 实现方案的延迟与 DSP 用量

### 3.3.6 测温台

图 3-13(a) 为一轮阶梯控温的实测记录，反馈点按设定值逐级升降，34 min 内覆盖 31.1 °C 至 42.4 °C。图 3-13(b) 为加热全关时 33 min 的静置记录：单通道读数波动平均 0.049 °C，通道间固定偏差的标准差为 0.19 °C。




(a) 阶梯控温实测　　(b) 校准前通道偏差

图 3-13　测温台实测

# 第四部分　总结

## 4.1 可扩展之处

QCNN 推理核和测温台都是通用的，换一套训练数据和权重即可扩展到以下任务，硬件不用改。

**按点位预警。**QCNN 已输出 9 路温升估计。积累更多按测点标注的数据后，可以指出是哪一段管路在升温，而不只是“沿线有异常”。

**绝对温度检测。**配合稳频或带温控的激光器，散斑与温度的对应关系更稳定，可在报警之外估计各段的绝对温度。

**泄漏检测。**冷却液泄漏会让管壁局部降温，并带来振动和形变，散斑对这些都敏感。相机最高 299 帧/s，可用帧间变化检测泄漏。

**脏堵检测。**冷板或支管脏堵时，下游温度缓慢升高、流量下降，可利用多点温升的时间关系识别。

**整机提速。**平场校正目前在 PS 上每帧约 2 s，改用分级降采样后为 41 ms，进一步移入 PL 后采集到推理可全程不经 PS；推理核 100 MHz 下仍有 2.5 ns 时序裕量，可提高时钟。

## 4.2 心得体会

从实测出发确定测量目标，是本作品最重要的一步。最初的方案是逐帧回归各点温度，在公开数据集上可行，但在自建测温台上，恒温时散斑几十秒就明显变化，任何模型都无法把它和温度分开。测清这一规律后，任务改为窗口化的温升报警，采集方案也随之改为锁定曝光、多帧中位数和专门的对照段。

评估协议要先于模型确定。我们一度在训练数据里混入了对照段，模型的小温升 AUC 达到 0.95 以上，把对照段也留出后降到 0.76。此后所有方法都用同一套留出划分和同一条报警规则比较，门限只用训练折的对照数据确定。

硬件与模型之间的一致性依赖统一的定点参考模型。权重、参数头文件与测试向量都由同一个脚本导出，RTL 仿真对每一层特征图逐点比对，换一套训练权重后，几分钟内就能完成回归验证。

采集链调试中，示波器之外最有效的手段是在 PL 中加入可读的状态寄存器：各 lane 的 LP 状态、同步字命中率与 ECC 统计。lane1 的故障正是通过这些计数定位到连接器的单个引脚。

## 4.3 大模型协作与技能包

开发全程使用大模型编程助手协作，完整交互记录（提示词、模型回答与自我纠错过程）放在仓库 report/llm_log/。协作方式是按任务拆成多个并行会话：采集链调试、数据集交接、训练、漂移分析、对比实验和报告各占一个会话，会

话之间通过共享文档和消息交接结论。

典型的自我纠错有三类：板上 DMA 读结果时进程异常退出，助手根据内核日志定位到非对齐访问，改为逐字读取；综合后权重全为 0，助手通过综合后网表仿真定位到 initial 块被忽略；漂移分析中助手发现训练集混入对照段造成的指标虚高，主动改为留出对照段重新评估。

从这些经验中提炼出四项技能包，放在仓库 skill/：定点 CNN 参考模型导出与 RTL 逐位比对流程、必须做综合后网表仿真的情形、不依赖 PYNQ 的 AXI DMA 用户态驱动、ZynqMP 上不用 libdrm 设置显示模式。每项写明适用场景、用法、失效条件和来源，都不依赖本作品的题目。

### 4.4 复现说明

仓库按 AMD 指南推荐的目录结构组织。复现步骤为：创建 conda 环境并拉取开源 RTL 依赖；用 Verilator 或 xsim 运行推理核、DMA 链路与显示合成的仿真，与参考结果逐位比对；用 build/vivado/build_fz3b.tcl 在 Vivado 2026.1 中重建比特流；把比特流和 src/host 下的程序拷到板上，运行 board/fz3b 中的启动脚本。各步的命令与预期输出写在 README.md 与各目录的说明中。

# 第五部分　参考文献

[1] Yang L, Wang X, Wu T, et al. Deep learning-based multimode fiber distributed temperature sensing[J]. Sensors, 2025, 25(9): 2811.

[2] Vélez Hoyos F J, Arango J D, Aristizábal V H, et al. Enhancing temperature sensing in fiber specklegram sensors using multi-dataset deep learning models: data scaling analysis[J]. Photonics, 2026, 13(1): 84.

[3] Gao H, Hu H F, Zhan Q W. Tailoring temperature response for a multimode fiber[J]. Opto-Electronic Science, 2025, 4(1): 240004.

[4] Redding B, Popoff S M, Cao H. All-fiber spectrometer based on speckle pattern reconstruction[J]. Optics Express, 2013, 21(5): 6584-6600.

[5] Metzger N K, Spesyvtsev R, Bruce G D, et al. Harnessing speckle for a sub-femtometre resolved broadband wavemeter and laser stabilization[J]. Nature Communications, 2017, 8: 15610.

[6] Bruce G D, O'Donnell L, Chen M, et al. Overcoming the speckle correlation limit to achieve a fiber wavemeter with attometer resolution[J]. Optics Letters, 2019, 44(6): 1367-1370.

[7] Jacob B, Kligys S, Chen B, et al. Quantization and training of neural networks for efficient integer-arithmetic-only inference[C]//IEEE CVPR. 2018: 2704-2713.

[8] Duarte J, Han S, Harris P, et al. Fast inference of deep neural networks in FPGAs for particle physics[J]. Journal of Instrumentation, 2018, 13(07): P07027.

[9] He K, Zhang X, Ren S, et al. Deep residual learning for image recognition[C]//IEEE CVPR. 2016: 770-778.

[10] Howard A, Sandler M, Chu G, et al. Searching for MobileNetV3[C]//IEEE ICCV. 2019: 1314-1324.

[11] Dosovitskiy A, Beyer L, Kolesnikov A, et al. An image is worth 16x16 words: transformers for image recognition at scale[C]//ICLR. 2021.

[12] Naug A, et al. LC-Opt: benchmarking reinforcement learning and agentic AI for end-to-end liquid cooling optimization in data centers[C]//NeurIPS Datasets and Benchmarks Track. 2025.

[13] AMD. Zynq UltraScale+ device technical reference manual (UG1085)[Z].

[14] AMD. AXI DMA LogiCORE IP product guide (PG021)[Z].

[15] MIPI Alliance. MIPI CSI-2 specification[S].

[16] OASIS. MQTT version 3.1.1[S]. 2014.

[17] Oak Ridge National Laboratory. Building an exascale-class data center[EB/OL]. (2020-12-14). https://www.olcf.ornl.gov/2020/12/14/building-an-exascale-class-data-center/.

[18] International Energy Agency. Energy and AI[R]. Paris: IEA, 2025.