基于 FPGA 的单光纤沿线温升实时报警边缘终端

摘要

以 Frontier 为代表的 E 级超级计算机和新建 AI 数据中心大量采用冷板式液冷。现有测点集中在冷却塔、冷水机组和 CDU 等设施级设备上，冷板和支管一级缺少能密集布设的温度测点。电学探头要逐点布线，在高压直流配电环境里还会受电磁干扰；光纤光栅和分布式光纤系统依赖昂贵的解调设备。

本作品是一套面向液冷管路的光纤沿线温升报警系统，由三个子系统协作完成：测温与控温子系统由 STM32、16 路加热片和 13 支探头组成，在管路上制造受控温升并记录真实温度，用于采集数据和标定；光路子系统由激光器、一根沿管路布设的多模光纤和全局快门相机组成，把光纤上的温度变化转成散斑图样的变化；FPGA 边缘节点在一块 Zynq UltraScale+ ZU3EG 板卡上完成散斑采集、推理、报警、显示和 MQTT 上报。

实测发现，即使温度不变，散斑图样也会在几十秒内随激光器状态慢慢改变。为此设计了窗口化报警方法：把 60 s 内的散斑帧平均，比较相隔 120 s 的两个窗口。PL 上的定点卷积网络 QCNN 从两个窗口的图样中学习温升特征，给出 9 路温升估计；同时计算两个窗口的去相关程度，衡量图样的整体变化。前者能学到与位置有关的温升信息，换数据重新训练即可扩展到更多任务，后者不需训练、对漂移稳健，两路融合后按“连续 3 次超限”的规则报警。

在自建测温台的 9 段留出数据上，2 min 内单路升温不少于 1 °C 时检出率 92%，30 次升温事件全部报警，报警延迟中位 25 s。和同一协议下微调的 ResNet-18、MobileNetV3-S 相比，检出率相当，延迟更短，计算量只有它们的 1/8 到 1/270。PL 侧自主实现 MIPI D-PHY 接收、CSI-2 解析、QCNN 推理核和整屏显示合成，推理核在 100 MHz 下稳态每帧 565 μs，输出与定点参考模型逐位一致；板上单帧推理 1.33 ms，比在同一块板的 ARM 核上运行现成网络快 70～2000 倍。

关键词：多模光纤散斑；温升报警；FPGA；量化卷积神经网络；液冷监测

目　录

摘要 1
第一部分　作品概述 3
1.1 散斑测温原理 3
1.2 功能与特性 3
1.3 应用领域 4
1.4 主要技术特点 5
1.5 主要性能指标 5
1.6 主要创新点 5
1.7 设计流程 6
第二部分　系统组成及功能说明 7
2.1 整体介绍 7
2.2 硬件系统介绍 10
2.3 软件系统介绍 12
第三部分　完成情况及性能参数 16
3.1 整体介绍 16
3.2 工程成果 16
3.3 特性成果 18
第四部分　总结 23
4.1 可扩展之处 23
4.2 心得体会 23
4.3 大模型协作与技能包 23
4.4 复现说明 24
第五部分　参考文献 25

第一部分　作品概述

本报告分五部分。第一部分介绍散斑测温原理、作品功能、应用背景、技术特点、性能指标和设计流程；第二部分介绍系统组成，包括三个子系统的硬件、PL 与 PS 的软硬件划分、报警方法和 QCNN 推理核；第三部分给出实物、PL 资源与时序、报警效果、与其他方法的对比和板上实测结果；第四部分总结可扩展方向、心得体会、大模型协作与复现方法；第五部分为参考文献。

1.1 散斑测温原理

激光射入多模光纤后，会分成上百个传播路径不同的“模式”，各自走过不同的光程。到达出射端时，这些模式互相叠加，有的地方加强，有的地方抵消，在屏幕上形成明暗相间的颗粒状图样，称为散斑，如图 1-1 所示。

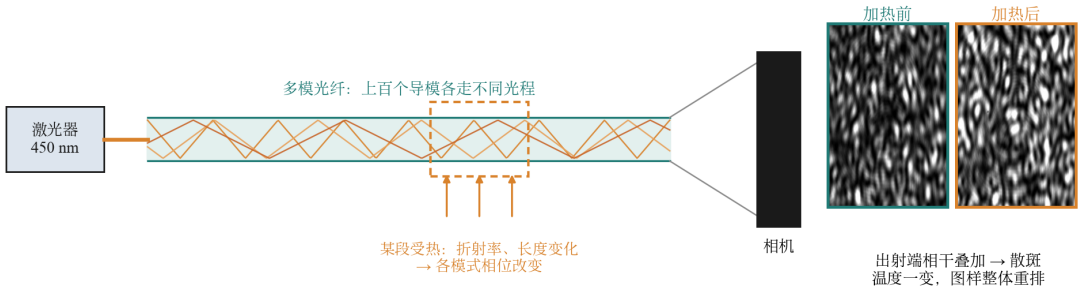


图 1-1　多模光纤散斑测温原理

光纤某一段受热时，玻璃的折射率和光纤长度都会变化，各模式的光程随之改变，叠加结果也就不同，散斑图样整体重排。因此，比较前后两张散斑图的相似程度，就能知道光纤沿线有没有地方在升温。相似度下降越快，温度变化越大。一根光纤上任何一段受热都会反映在同一张图上，所以一根光纤可以监测整段管路。

1.2 功能与特性

作品是一台安装在液冷支管旁的报警终端，由一根多模光纤、一台相机和一块 FPGA 开发板组成，主要功能如下。

沿线温升报警。光纤沿线任一位置在 2 min 内升温 1 °C 以上时，终端在约半分钟内报警。

本地显示。屏幕显示沿线状态、报警得分曲线、实时散斑画面和报警记录，现场可直接查看。

平台接入。经 MQTT 向运维平台发布在线状态、每步得分和报警事件，并

接收远程复位指令。

独立运行。采集、推理、判断、显示与上报全部在一块板卡上完成，部署时只需光纤、相机和板卡。

光纤不导电、不受电磁干扰，适合高压配电环境；一根光纤覆盖一整段管路，不需要逐点布线。

1.3 应用领域

大型算力设施已普遍转向液冷。美国橡树岭国家实验室的 Frontier 是第一台 E 级超级计算机，峰值功耗 29 MW，整机采用 32 °C 温水冷却，两座冷却塔和四台水泵每台每分钟输送约 3.8 万升冷却水[17]。AI 训练进一步推高了用电：国际能源署估计，全球数据中心用电量 2024 年约 415 TWh，到 2030 年将翻倍至约 945 TWh[18]。冷却回路一旦出现冷板堵塞、流量分配不均或局部泄漏，轻则芯片降频，重则停机。管路运维因此成为算力设施的关键问题，能尽早发现局部温升，就能少停机、少浪费电。

作品面向这类液冷系统的末端监测，图 1-2 给出它在冷却链路中的位置。设施级测点集中在一次侧，而热量的源头在二次侧的冷板与支管，这里测点稀疏，局部温升往往要等芯片降频后才被发现。本作品把监测范围下沉到支管和冷板一级，报警经 MQTT 汇入上层运维平台。

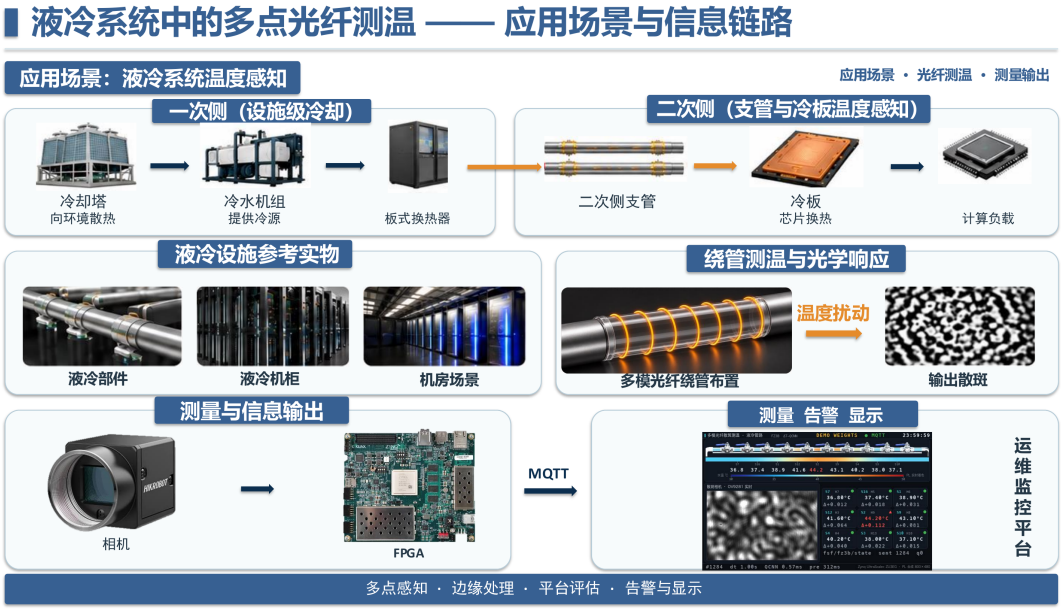


图 1-2　作品在液冷链路中的位置

同一方案也可用于储能电池簇、高压母排和电机绕组等探头难以布设、电磁环境恶劣的场合。

1.4 主要技术特点

本节从三个方面说明作品的技术特点。

（1）系统集成：水路、光路、电路协同。作品由测温与控温、光路、FPGA 边缘节点三个子系统组成。加热片、探头与光纤在水管上的布置，激光器、光纤与相机的耦合，加热、测温与相机采集的时间对齐，都按统一的接口和时间基准设计，才能得到可重复的实验条件。

（2）数据与算法：自建测温台、数据集与窗口化报警。测温台自动控温，同步记录散斑帧、探头温度和加热功率，并录制不加热的对照段。在这些实测数据上发现了激光漂移，据此设计窗口平均、QCNN 与去相关融合的报警方法，门限和融合参数都由对照数据标定。

（3）FPGA 实现：自主 PL 通路，高性能、低功耗、低资源。D-PHY 接收、CSI-2 解析、QCNN 推理核与显示合成均为自主编写的 RTL。推理核层内按输出通道并行，层间以帧为单位流水，中间特征图不经 DDR，用 30% 的 DSP 和约 0.3 mJ 的单次能耗完成实时推理。

1.5 主要性能指标

表 1-1　主要性能指标

指标	数值	条件
温升检出率	92%（≥1 °C/2 min）	对照误报 1%，9 段留出数据
升温事件检出	30/30	单路设定上调 ≥2 °C
报警延迟	中位 25 s	升温开始到报警
散斑采集帧率	149.8 fps	640×800 RAW8，板上实测
推理吞吐	565 μs/帧	100 MHz，RTL 仿真
板上单帧推理	1.33 ms	含 DMA 往返，板上实测
PL 资源	LUT 28.8%　DSP 30.0%　BRAM 24.8%	合并比特流，布线后
片上功耗	2.99 W	Vivado 估计
显示输出	800×480 @ 60 Hz	Mini DP，7 英寸屏

1.6 主要创新点

① 用一根多模光纤的散斑实现整段管路的温升报警，替代逐点布设的探头。

② 针对实测的激光漂移，提出窗口平均、QCNN 与去相关融合、规则判定三步组成的报警方法，门限只依赖不加热的对照数据。

③ 自主实现的 FPGA 散斑处理流水线，采集、推理与显示合成在 PL 完成，推理层间数据不经 DDR。

④ 感知、报警、显示与平台上报在单块板卡上闭环。

1.7 设计流程

设计流程如图 1-3 所示，分为测温台与数据、算法与模型、FPGA 实现三条主线。测温台主线搭建水路、光路和电路，按设定序列录制加热段与不加热的对照段；算法主线在这些数据上设计窗口化报警方法，完成量化训练，并导出定点参考模型；FPGA 主线完成 RTL 设计、逐位比对仿真、Vivado 实现和上板测试。定点参考模型是后两条主线的接口，上板实测结果再反馈到采集方案和报警方法。

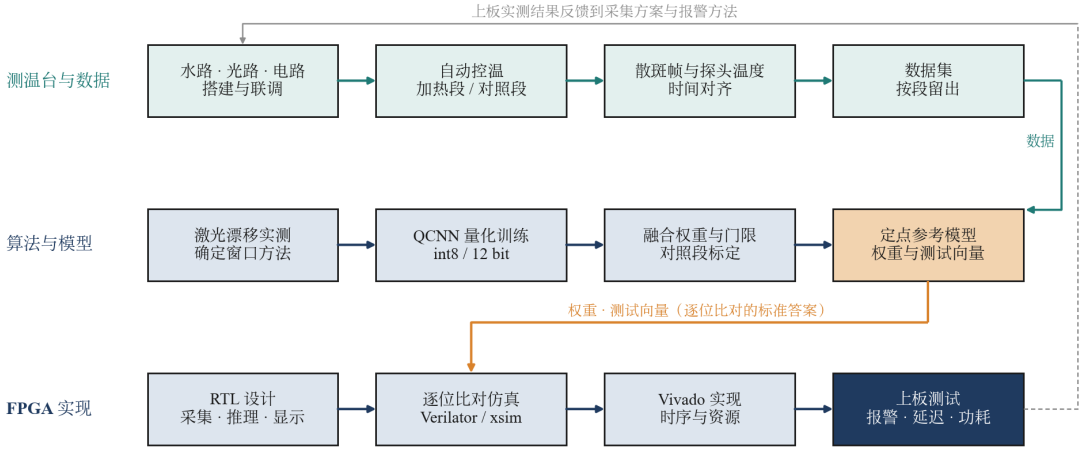


图 1-3　设计流程

第二部分　系统组成及功能说明

2.1 整体介绍

2.1.1 系统组成

系统由测温与控温、光路、FPGA 边缘节点三个子系统组成，如图 2-1 所示。测温与控温子系统以 STM32 为主控，驱动 16 路加热片在光纤上制造受控温升，并以 13 支数字探头记录真实温度；光路子系统由激光器、多模光纤与全局快门相机组成，把光纤上的温度变化转成散斑图样的变化；FPGA 边缘节点完成采集、推理、报警、显示与上报。测温台只在采集训练与评估数据时使用，部署时节点只需要光纤和相机。

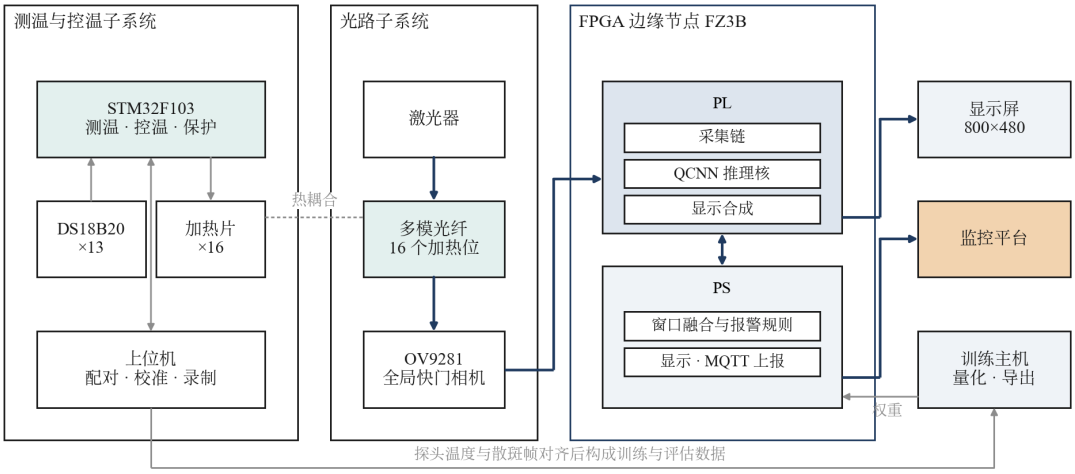
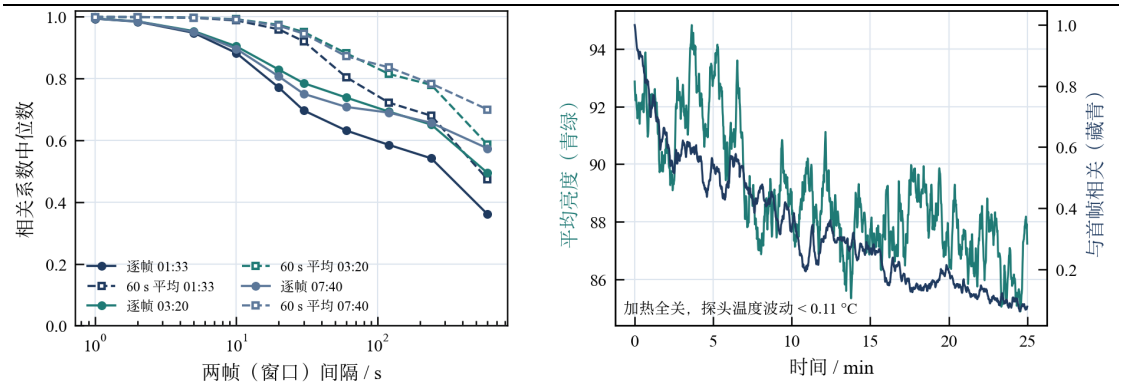


图 2-1　系统组成

2.1.2 散斑传感原理与漂移

激光在多模光纤中激发大量导模，各模式相位不同，在出射端面相干叠加形成散斑。温度通过热光效应和热膨胀改变各模式相位，散斑随之重排，变化程度可用两帧之间的相关系数度量。

图 2-2 是加热全关时的实测结果。两帧相隔 60 s，相关系数已降到 0.6～0.7，而探头温度几乎不变。这一漂移来自激光器的波长与功率起伏，在几十秒内来回摆动，几小时后的图样也不会回到原来的状态。因此，单帧图样无法对应到固定的温度。把 60 s 的帧平均后再比较，同样间隔下的相关系数明显回升，说明平均能抵消大部分漂移。本作品的报警方法即建立在这一实测规律上。



(a) 恒温下相关系数随间隔下降　　(b) 一段 25 min 恒温记录

图 2-2　恒温条件下的散斑漂移

2.1.3 数据流

FZ3B 上的数据流如图 2-3 所示，按编号依次为：

① 采集。OV9281 输出 MIPI CSI-2 数据，PL 中的 D-PHY 接收与 CSI-2 解析模块恢复像素流，经打包与跨时钟域 FIFO 后由 VDMA 写入 DDR4。

② 预处理。PS 读取最新一帧，完成行合并、平场校正与标准化，并累入 60 s 滑动窗口。

③ 推理。AXI DMA 把两个窗口的平均图样（56×56）送入 QCNN 推理核，各层特征图保存在本层输出 RAM 中。

④ 判断。9 路温升估计经 DMA 写回 DDR4，PS 把它与窗口去相关得分融合，按报警规则判定。

⑤ 显示。PS 更新屏幕状态，PL 读取 DDR 中的背景与相机帧，逐像素合成 800×480 画面，经 DPSUB 实时视频层输出。

⑥ 上报。PS 通过以太网以 MQTT 协议发布状态与报警。

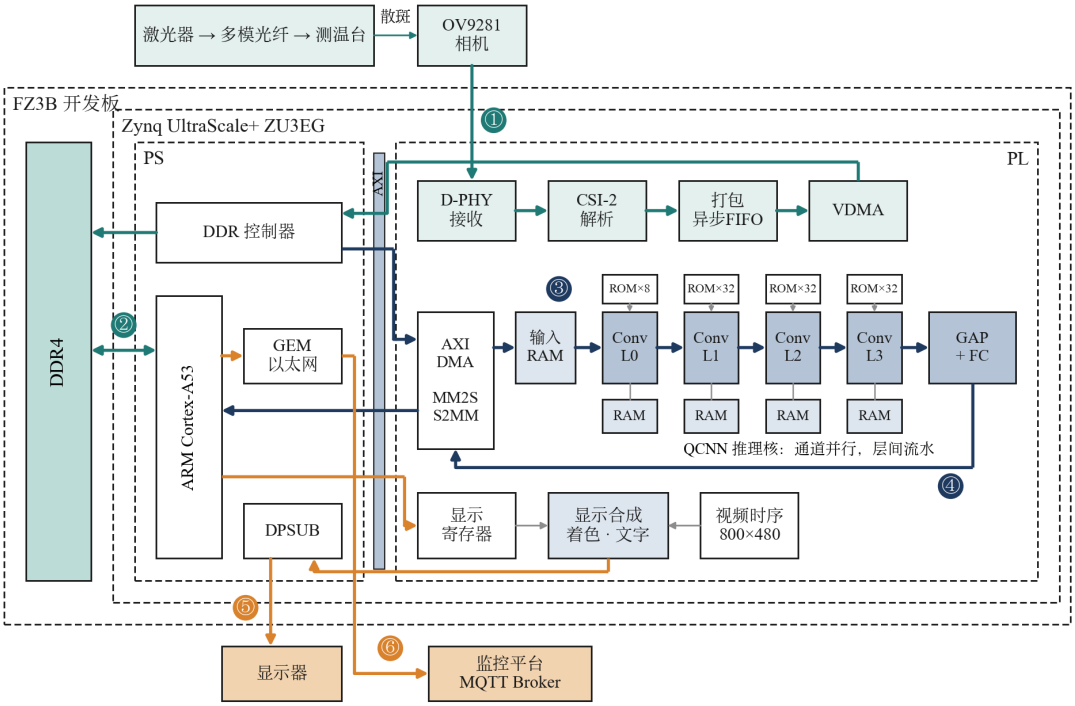


图 2-3　数据流

2.1.4 报警方法

报警方法如图 2-4 所示，分三步。

窗口平均。每 5 s 取一次最近 60 s 的平均图样作为窗口 B，与 120 s 前的平均图样（窗口 A）比较。120 s 的间隔让光纤有时间升温，60 s 的平均抵消大部分激光漂移。

两路得分。QCNN 在 PL 上运行，输入两个窗口的 56×56 平均图样，输出 9 路温升幅度，取最大值；PS 同时把两个窗口降到 10×16 块，计算 1 减相关系数。两路得分各自按不加热对照数据的均值和标准差标准化，加权相加得到报警得分。

为什么用两路。窗口去相关不需要训练，只衡量图样整体变了多少，对激光漂移稳健，但它分不出变化来自哪里、也无法从数据中改进。QCNN 能从两个窗口的图样中学到与温升有关的空间特征，输出按测点分开的 9 路估计，数据越多、标注越细，能力越强；同一个推理核换一套权重，就能用于按点位报警、绝对温度估计、泄漏或脏堵检测等任务，硬件不用改。两路互补：去相关保证在漂移下的稳健性，QCNN 提供可学习、可扩展的部分。

报警规则。得分连续 3 次超过门限即报警，报警后冷却 300 s 再允许下一次。门限取对照数据得分的 99.5% 分位。整个方法只有门限一个参数需要从对照数据确定，换一根光纤或换一个场地，录一段不加热的数据即可重新标定。

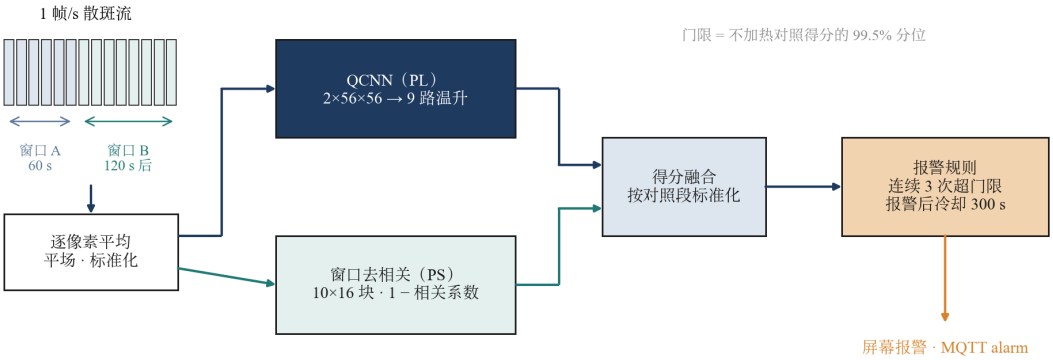
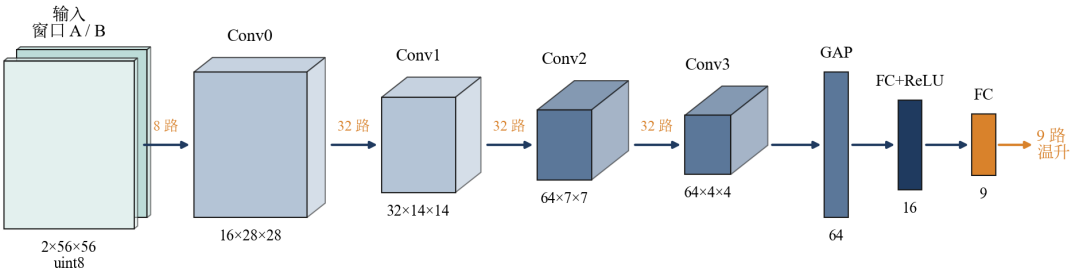


图 2-4　报警方法

2.1.5 QCNN 推理核

网络结构如图 2-5 所示。输入为 2×56×56 的两个窗口平均图样，经四层 3×3、步长 2 的卷积降到 64×4×4，再经全局平均池化与两层全连接输出 9 路温升幅度。网络共 6.2 万个参数，单次推理 2.6 MMAC。权重为 int8，激活为 12 bit 无符号数，层间以移位方式重新量化，全程整数运算。



卷积核 3×3、步长 2；权重 int8，激活 12 bit，逐层移位重量化；橙色数字为该层并行乘法器路数；层间以帧为单位流水

图 2-5　QCNN 网络结构

卷积层内，一个输入激活同时送往 PAR 路乘法器，每路持有本组输出通道的权重 ROM，一次读取驱动 PAR 次乘加；四层的并行度分别为 8、32、32、32。各层拥有独立的输出 RAM，层间以握手传递帧，多帧可同时处于不同层中。100 MHz 下推理核稳态每帧 565 μs，首帧延迟 1.12 ms；以训练好的权重和 16 组实测窗口对仿真，144 个输出与定点参考模型逐位一致。

2.2 硬件系统介绍

2.2.1 硬件整体介绍

硬件由测温台、光路与 FPGA 节点三部分组成，连接关系如图 2-6 所示。测温台的控制箱经 USB 串口与上位机通信，16 路加热片与 13 支探头沿光纤

布置；光纤出射端正对相机，相机经转接板以 MIPI 接入 FZ3B；FZ3B 经千兆网口接入交换机，经 Mini DP 驱动 7 英寸 800×480 显示屏。主要器件见表 2-1。

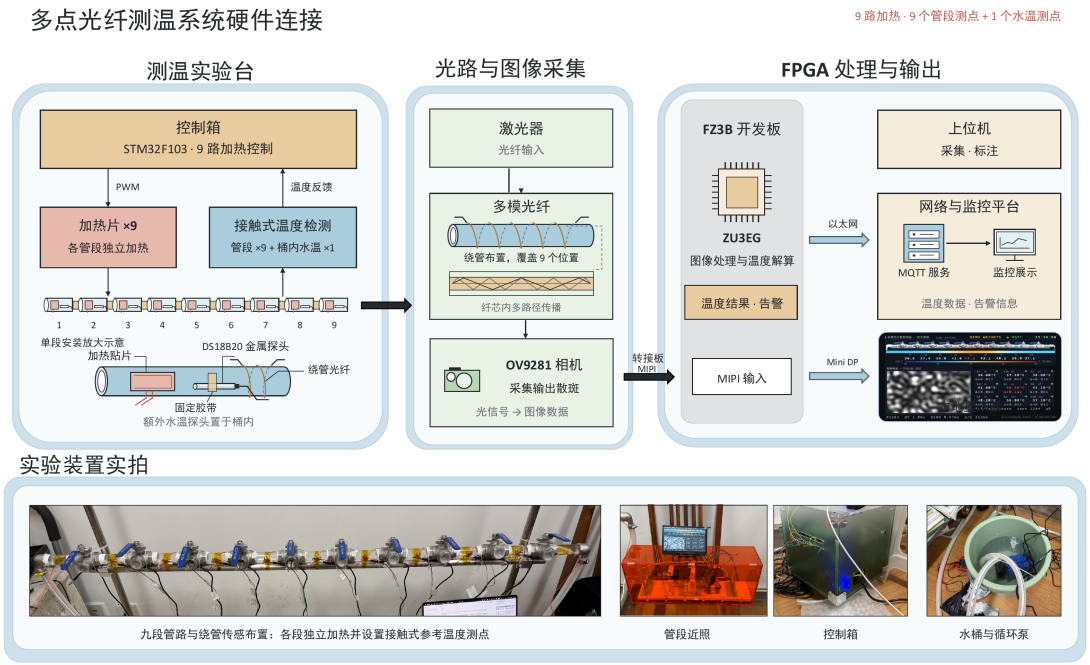


图 2-6　硬件连接

表 2-1　主要器件

模块	型号与规格	数量	作用
FPGA 平台	EdgeBoard FZ3B，ZU3EG，DDR4 4 GB	1	采集、推理、显示、通信
相机	OV9281，1280×800，全局快门，RAW8	1	散斑采集
光源	450 nm 半导体激光器	1	照明
光纤	通用多模光纤，3 m	1	传感
测温主控	STM32F103C8T6，72 MHz	1	测温、控温、保护
测温探头	DS18B20，12 bit	13	真实温度记录
加热	硅胶加热片 12 V / 5 W，MOS 低侧开关	16	受控加热
显示屏	7 英寸 800×480，Mini DP	1	本地显示

2.2.2 机械设计介绍

控制电路、电源与接线端子收纳在 250 mm 立方的亚克力箱体内，箱体用 5 mm 亚克力激光切割，四面墙板等尺寸搭接，前墙与侧墙开长槽分别引出加热导线与探头导线。光纤段用导热胶贴在各加热位上，加热片与探头分置光纤两侧，使探头读数代表光纤所在位置的温度。相机与光纤出射端固定在同一底板上，外

加遮光罩，减少杂散光与机械扰动。

2.2.3 电路各模块介绍

测温通道。每支 DS18B20 独占一个 GPIO。单支探头断线或短路只影响本通道，故障可直接定位到引脚；13 支探头同时启动转换，750 ms 后依次读取。

加热通道。三片 74HC595 级联，用 3 根信号线扩展出 16 路控制，分别驱动 16 个 MOS 模块。595 输出使能脚上拉、MOS 栅极下拉，复位或程序未运行时全部加热片关断。12 V 加热回路与逻辑回路分开走线，单点共地。

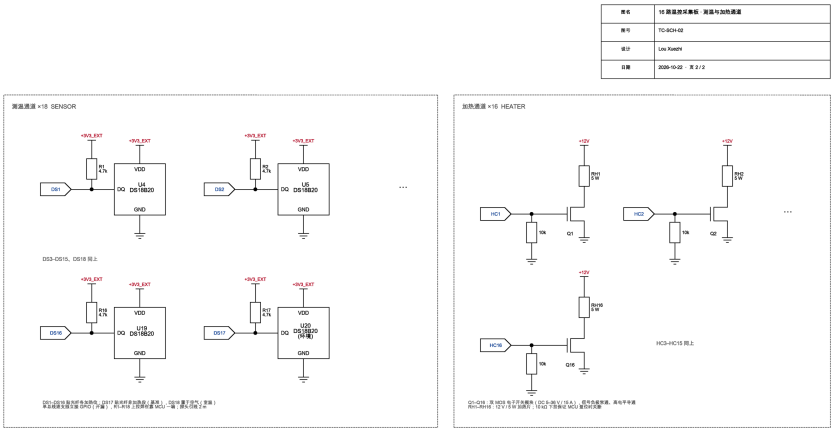


图 2-7　测温通道与加热通道原理图

相机接口。OV9281 的 MIPI 时钟与数据线经转接板接入 FZ3B 的 HP Bank 64，PL 用 IBUFDS_DPHY 原语直接接收差分信号，不依赖 MIPI D-PHY 硬核 IP。表 2-2 为 PL 的引脚分配。

表 2-2　PL 引脚分配

信号	引脚	电平标准	说明
MIPI CLK P / N	AD5 / AD4	MIPI_DPHY_DCI	800 Mb/s 位时钟
MIPI D0 P / N	AC4 / AC3	MIPI_DPHY_DCI	数据 lane 0
MIPI D1 P / N	AB4 / AB3	MIPI_DPHY_DCI	数据 lane 1
cam_mclk	L7	LVCMOS18	相机主时钟 24 MHz
cam_rst_n / cam_pwdn_n	U9 / Y8	LVCMOS18	相机复位与掉电
pl_ref_clk	D4	LVCMOS18	25 MHz 参考时钟

2.3 软件系统介绍

2.3.1 软件整体介绍与软硬件划分

软件分为 PL 逻辑、PS 节点程序、测温台固件与离线工具四层，见表 2-3。PL 与 PS 之间通过 AXI4-Lite 寄存器与 AXI DMA 交互。

表 2-3　软件组成

层次	模块	实现	功能
PL	采集链	Verilog	D-PHY 接收、CSI-2 解析、VDMA 写帧
PL	QCNN 推理核	Verilog	2×56×56 → 9 路温升定点推理
PL	显示合成	Verilog	背景、着色、相机画面、文字叠加
PS	节点程序	Python	预处理、窗口、DMA 调度、融合、报警、MQTT
测温台	固件	C / HAL	1 s 节拍测温、PID 控温、多级保护
离线	训练与导出	Python	量化训练、定点参考模型、权重与测试向量

软硬件划分按三条原则确定。第一，数据量大、节拍固定的部分放 PL：MIPI 解串必须在 PL 完成，每帧 51 万像素的显示合成在 PS 上做不到 60 Hz。第二，运算密集且结构规整的部分放 PL：QCNN 一次推理 2.6 MMAC，同一网络在 A53 上用定点实现要 33.5 ms，在 PL 上 1.33 ms。第三，逻辑分支多、需要网络协议栈的部分放 PS：报警规则、MQTT 与远程指令都在 PS。窗口去相关只有 160 维，PS 上每次不到 1 ms，没有必要占用 PL。

2.3.2 软件各模块介绍

（1）采集链。链路结构如图 2-8 所示。时钟 lane 经 IBUFDS_DPHY 与 BUFGCE_DIV 产生位时钟和四分频字节时钟；数据 lane 经 IDELAYE3 调整采样相位，ISERDESE3 完成 1:8 解串。每个 lane 有独立的 LP 状态机，在 HS 突发起始处搜索同步字 0xB8，同时检查正反两种极性，板级 P/N 交换不需要改约束。CSI-2 解析模块校验包头 ECC 与载荷 CRC，任何一项校验失败即丢弃到 EoT。像素经 16→64 位打包与异步 FIFO 跨入 AXI 时钟域，由 VDMA 以四帧存方式循环写入 DDR4。

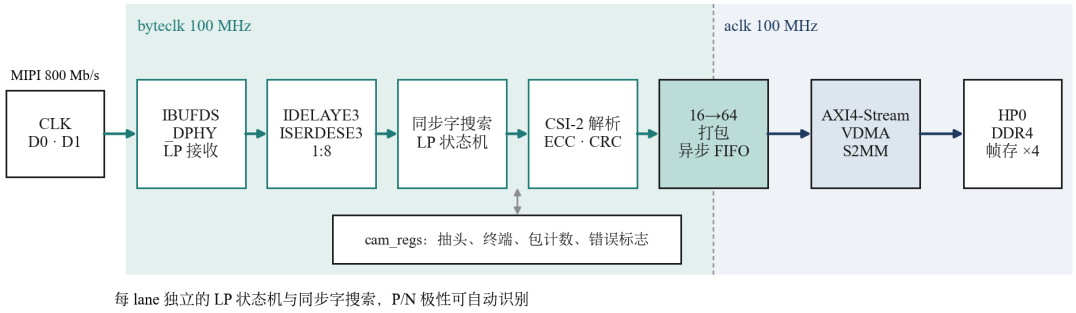


图 2-8　PL 采集链

（2）卷积层。单层数据通路如图 2-9 所示，按 S0 到 S4 五级流水运行。S0 依次遍历输出坐标、输出通道组与卷积抽头，S1 生成源特征图地址，S2 读

出一个输入激活并同时送入 PAR 路乘法器，S3 累加，S4 按层移位量重新量化并钳位到 12 bit。层与层之间以 valid / taken 握手：本层写完一帧后置 dst_valid，下一层读走后释放，本层随即开始下一帧。

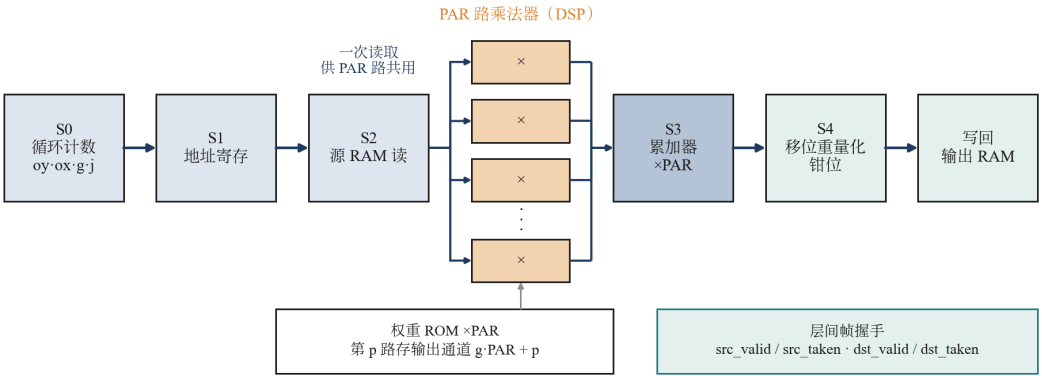


图 2-9　卷积层数据通路

（3）定点方案。训练分浮点预训练、激活范围校准和量化感知训练三步。权重量化为 int8，激活为 12 bit 无符号数，偏置为 int32。每层的缩放因子取 2 的整数次幂，重新量化只需算术右移。定点参考模型 qcnn_int.py 与 RTL 用同一套移位与舍入规则，导出 .mem 权重文件、参数头文件与测试向量。训练时随机交换两个窗口的顺序并做小幅平移，让网络对图样整体位置和比较方向不敏感。

（4）显示合成与界面。PL 逐像素合成 800×480 画面：静态背景预先渲染后放在 DDR，PL 按行读取背景与相机帧存，动态数字由 12×24 字模 ROM 叠加，暂存寄存器在场消隐期统一生效，画面无撕裂。PS 触屏界面提供总览、散斑视图和报警记录等页面，图 2-10 为总览页与报警页。



图 2-10　终端界面：(a) 总览　(b) 报警

（5）节点程序。程序流程如图 2-11 所示。采集线程只保留最新一帧；主循环每个周期取出该帧，完成平场与标准化后并入滑动窗口，每 5 s 经一次 DMA 调用得到 QCNN 温升估计，与窗口去相关融合后按规则判定。报警状态变化时以 QoS 1 发布。MQTT 收发在独立线程中进行，队列有界，Broker 断开不阻塞推理与显示。

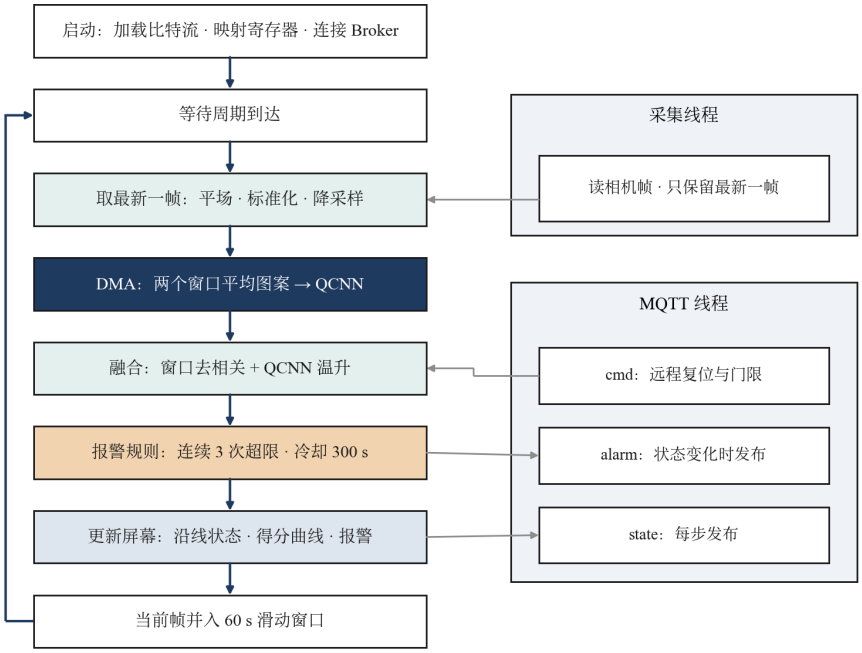


图 2-11　节点程序流程

（6）MQTT 主题。节点以 fsf/<节点名>/ 为前缀发布与订阅，见表 2-4。

表 2-4　MQTT 主题

主题	方向	QoS	内容
status	发布	1，保留	在线状态；遗嘱消息为 offline
state	发布	0	每步报警得分、门限、各阶段耗时
alarm	发布	1	报警事件：时刻、得分、门限
cmd	订阅	0	远程复位、门限调整

（7）测温台固件与数据采集。固件以 1 s 为周期：13 支探头同时启动转换，800 ms 后读回并完成每路 PID 计算，随后发出一帧带校验的 ASCII 数据。加热输出采用时间比例方式，2 s 窗口、1 % 分辨率。固件具备探头失效、过温跳闸、上位机失联与看门狗四级保护，复位后全部加热关断。采集时相机锁定曝光，每秒取 5 帧做逐像素中位数，以 1 帧/s 记录散斑、13 路温度和 16 路占空比。

第三部分　完成情况及性能参数

3.1 整体介绍

图 3-1 为测温实验台的九段管路，光纤绕管布置，各段独立加热；图 3-2 为水桶、循环泵与光路箱，触摸屏放在光路箱上方。

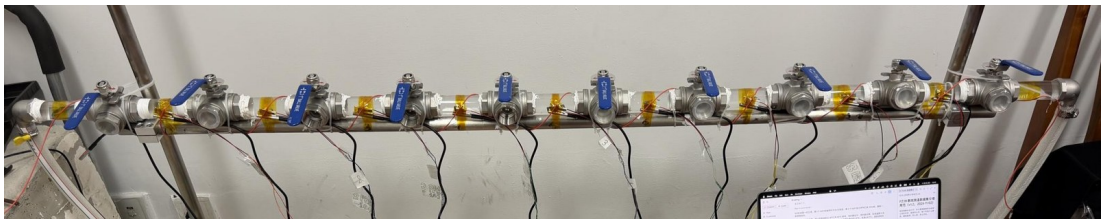


图 3-1　九段管路与绕管光纤，各段独立加热



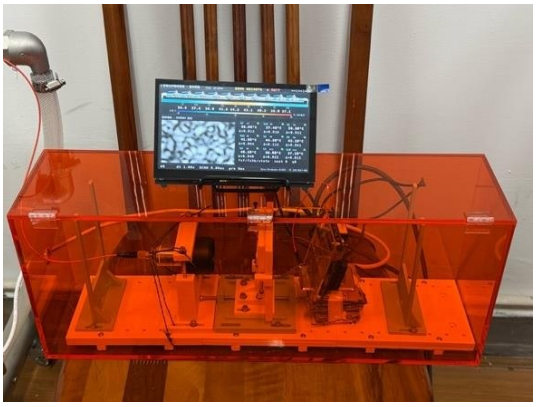


图 3-2　(a) 水桶与循环泵　(b) 光路箱与屏幕

3.2 工程成果

3.2.1 机械成果

控制箱为 250 mm 立方的亚克力箱体；光路暗箱用橙色亚克力遮挡环境光，内部固定光纤出射端与相机。



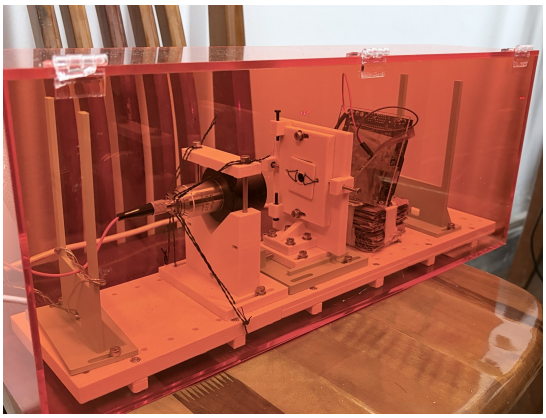


图 3-3　(a) 控制箱　(b) 遮光暗箱：光纤出射端正对相机

3.2.2 电路成果

测温主控板在洞洞板上焊接，STM32 核心板、74HC595 与 MOS 模块按图 2-7 连接；光源为 450 nm 半导体激光器，带电流显示。

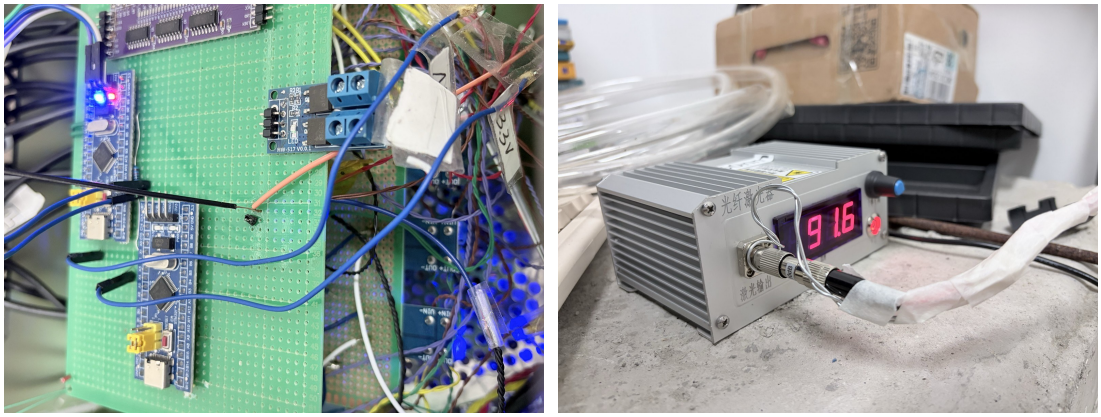


图 3-4 (a) 测温主控板 (b) 450 nm 半导体激光器

FPGA 节点为 EdgeBoard FZ3B（图 3-5），板上带散热风扇和千兆网口；OV9281 相机经自制转接板以 MIPI 接入板卡的扩展接口。

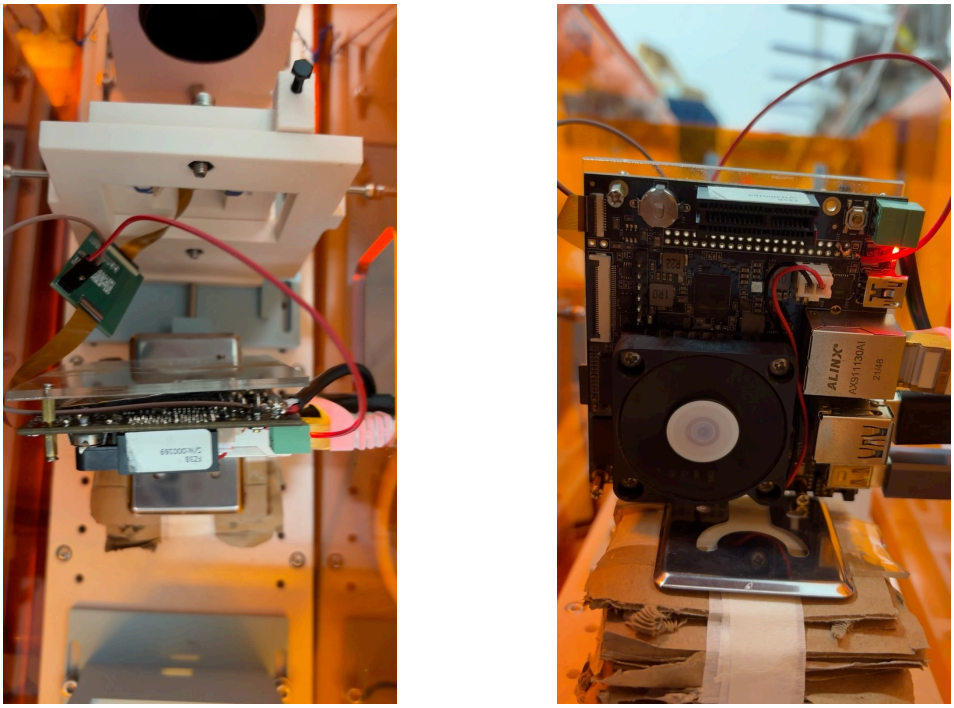


图 3-5 FZ3B 板卡与相机转接

3.2.3 软件成果

图 3-6 为 7 英寸触摸屏实拍：总览页显示管路沿线读数、光纤报警状态、实时散斑和各测点曲线。



图 3-6　终端屏幕实拍

PL 设计用 Vivado 2026.1 在 xczu3eg-sfvc784-1-i 上完成综合与实现，采集链、推理核（已载入训练权重）与显示合成合并为一个比特流，全部时钟域时序收敛。资源与时序见表 3-1。

表 3-1　PL 资源与时序

项目	用量	占比	说明
LUT	20322	28.8%	全设计
FF	20041	14.2%	
BRAM	53.5	24.8%	特征图与权重全部片上
DSP	108	30.0%	推理核 104
clk_pl_0 100 MHz	WNS +2.55 ns		AXI、DMA、推理核
vclk 74.25 MHz	WNS +8.26 ns		显示像素时钟
片上功耗	2.99 W		Vivado 估计

3.3 特性成果

3.3.1 数据集

测温台共录制 37 段数据，约 9.5 万帧，时间线如图 3-7 所示。第三次采集针对激光漂移重新设计：相机锁定曝光，每秒 5 帧取中位数，并加入 4 段全程不加热的纯对照和 5 段每档保持 8～10 min 的长平台。报警方法的训练与评估使用第三次采集的 11 段数据，共 3.4 万帧。

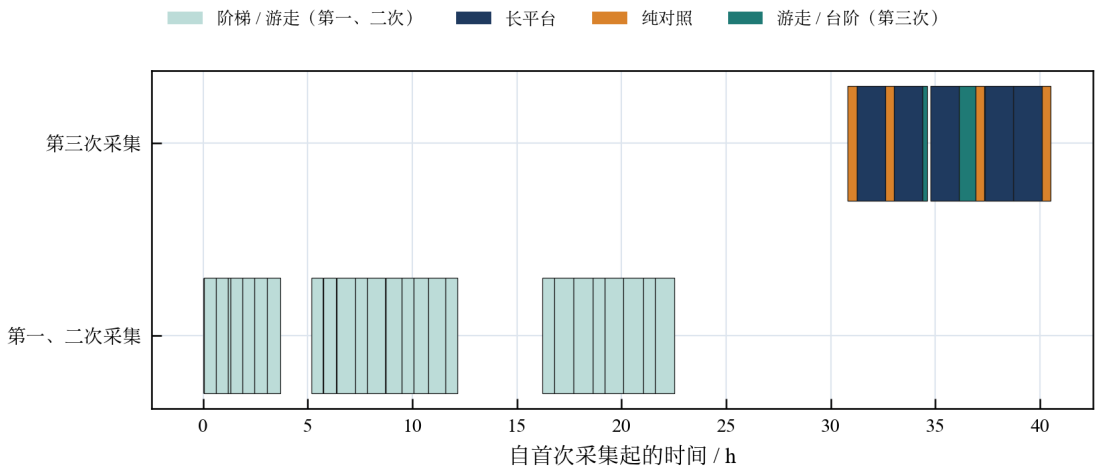


图 3-7　数据集时间线

评估采用留出方式：每次留出 1 段长平台和 1 段对照，其余数据训练 QCNN、确定融合权重和门限，共 5 折，每段长平台都当过一次测试集。标签取探头在两个窗口内的平均温差，对照段的标签为 0。探头比光纤慢 15～45 s，小温升档的检出率会因此偏低。

3.3.2 报警效果

图 3-8 是一段 80 min 长平台的报警过程。上图是加热各路的探头温度，下图是报警得分。每次设定上调后，得分在半分钟左右越过门限并报警；温度保持不变后，得分回落到门限以下。

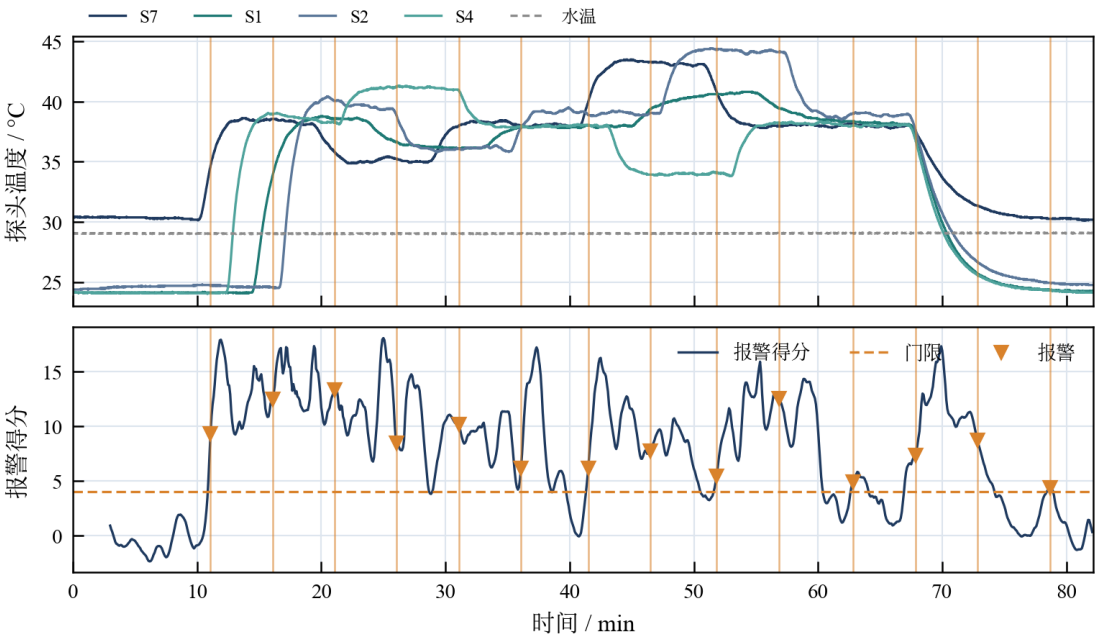


图 3-8　一段长平台的报警过程（留出数据）

图 3-9(a) 按 2 min 内单路最大温升分档统计检出率。温升不小于 2 °C 时检出 97%，1～2 °C 时 83%，0.25 °C 以下只有 6%，与对照段的误报水平相当。

图 3-9(b) 是 30 次升温事件的报警延迟，中位 25 s，90% 的事件在 235 s 内报警。4 段对照共 1.5 h，报警规则下误报 4 次，全部出现在同一段对照里，其余 3 段为 0 次。

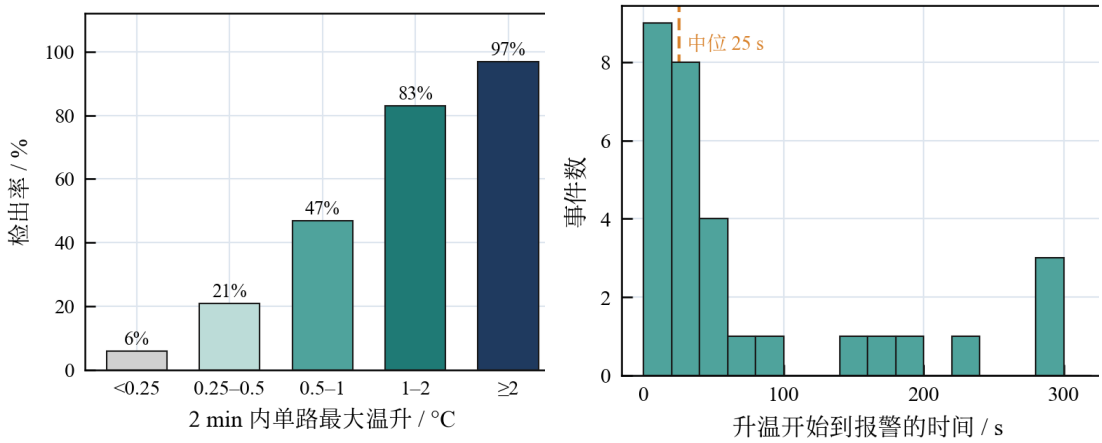


图 3-9 (a) 检出率随温升幅度 (b) 报警延迟

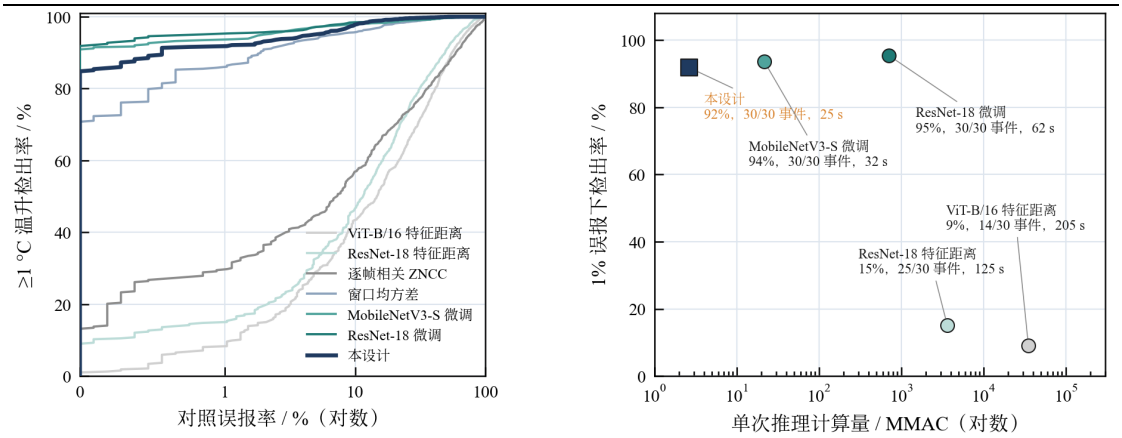
3.3.3 与其他方法对比

所有方法使用相同的窗口、相同的 5 折划分、相同的报警规则，门限都只用训练折的对照数据确定，结果见表 3-2 和图 3-10。对比对象包括：经典的逐帧散斑相关、窗口均方差、ImageNet 预训练的 ResNet-18 和 ViT-B/16 特征距离，以及在同样数据上微调的 ResNet-18 和 MobileNetV3-S。

表 3-2 同一协议下的报警方法对比

方法	AUC	检出率	事件检出	延迟中位	计算量 / MMAC
本设计	0.993	92%	30/30	25 s	2.6
ResNet-18 微调	0.994	95%	30/30	63 s	712
MobileNetV3-S 微调	0.992	94%	30/30	33 s	22
窗口均方差	0.986	86%	30/30	25 s	—
逐帧相关	0.816	30%	24/30	213 s	—
ResNet-18 特征距离	0.817	15%	25/30	125 s	3628
ViT-B/16 特征距离	0.777	9%	14/30	205 s	35126

AUC 与检出率针对 2 min 内单路升温不少于 1 °C 的窗口，检出率在 1% 误报下统计。不做时间平均的逐帧相关只能检出 30%，直接套用预训练网络的特征更差，说明漂移是这一任务的主要难点。本设计的检出率与微调后的 ResNet-18 相当，报警延迟短一半，计算量为其 1/270；与 MobileNetV3-S 相比，检出率相当，计算量为其 1/8。只有本设计的网络能在 PL 上实时运行，其余深度网络在板上 ARM 核上单帧需要 0.1～2.7 s。



(a) ROC　　(b) 检出率与计算量

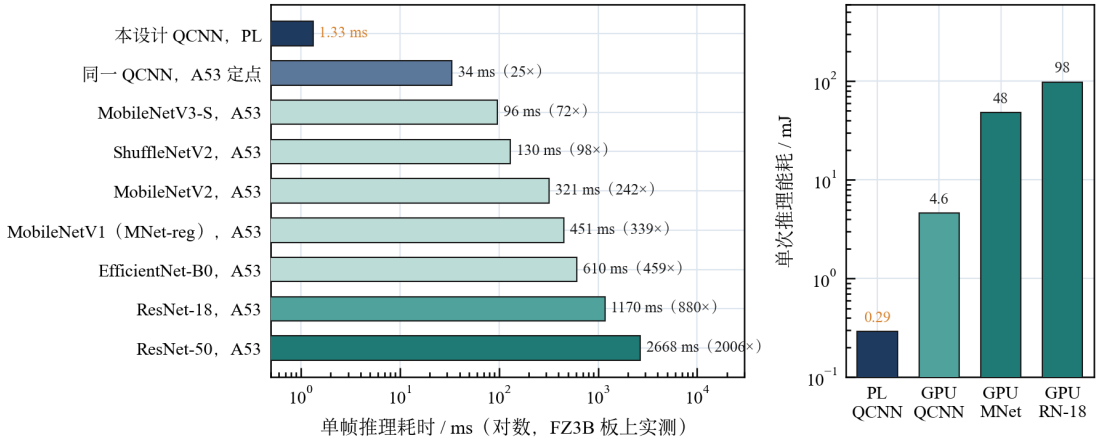
图 3-10　报警方法对比

3.3.4 散斑采集

采集链在板上连续运行，1280×800 模式下得到 640×800 图像 149.8 帧/s，640×400 合并模式下得到 320×400 图像 299.0 帧/s，10 s 内每帧行数完整、无坏包头、VDMA 无错误。

3.3.5 板上推理与优化效果

在 FZ3B 上分别测量 PL 推理核和 A53 上的软件实现，结果如图 3-11 所示。PL 单帧 1.33 ms，包含 Python 写缓冲、启动 DMA 与逐字读回；每批 16 帧时平均每帧 0.64 ms。载入训练权重后，板上 40 组输入（16 组实测窗口、24 组随机）的输出与定点参考模型逐位一致，单帧 1.34 ms。同一 QCNN 在 A53 上用定点实现要 33.5 ms，PL 快 25 倍；能部署到板上的现成网络在 A53 上需要 96～2668 ms，PL 快 70～2000 倍。按 Vivado 估计的推理核功耗乘实测延迟，PL 单次推理约 0.29 mJ，台式机 GPU 运行 MNet-reg 为 48 mJ。



(a) 板上单帧推理耗时　　(b) 单次推理能耗

图 3-11　板上推理耗时与能耗

推理核的结构经过两轮优化，见表 3-3 和图 3-12。初版每层只用 1 个乘法

器，单帧 18.06 ms；改为按输出通道并行、层间流水后降到 0.565 ms，DSP 由 7 个增加到 104 个。同一模型用 hls4ml 生成的实现在 XC7Z020 上 BRAM 需求为器件容量的 2～4 倍，无法布局。本设计在同一器件上 BRAM 占用 21%，时序收敛。

表 3-3　推理核优化前后对比（XC7Z020，同一模型）

实现	单帧延迟	DSP	BRAM_18K	能否布局
串行实现（优化前）	18.06 ms	7	—	能
本设计（并行 + 流水）	0.565 ms	104 / 220	60 / 280	能
hls4ml，复用因子 576	5.36 ms	106 / 220	603 / 280	超出容量
hls4ml，复用因子 64	2.70 ms	915 / 220	1080 / 280	超出容量

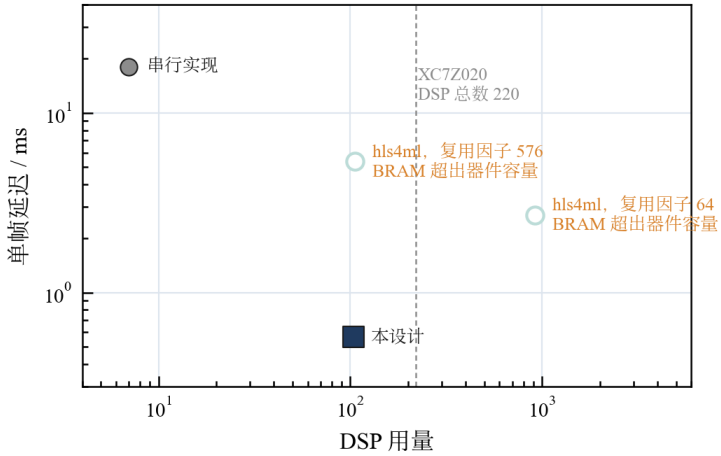
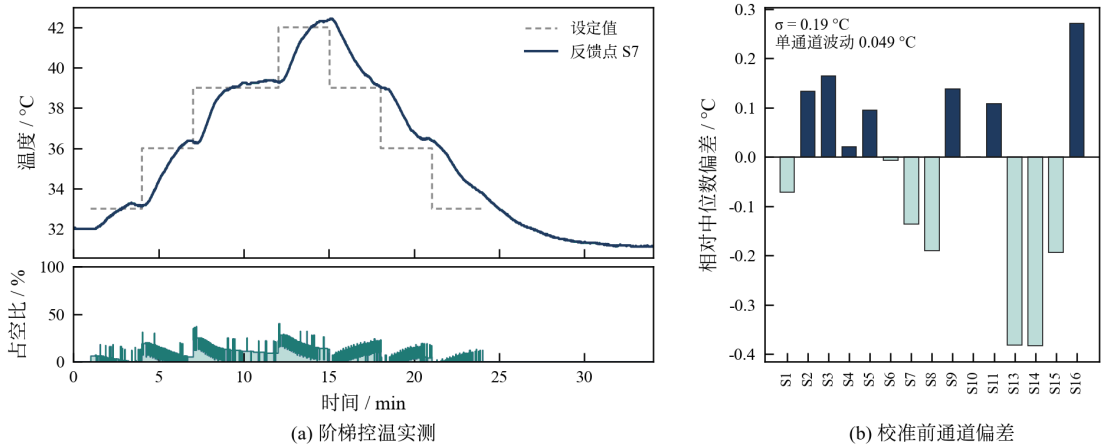


图 3-12　PL 实现方案的延迟与 DSP 用量

3.3.6 测温台

图 3-13(a) 为一轮阶梯控温的实测记录，反馈点按设定值逐级升降，34 min 内覆盖 31.1 °C 至 42.4 °C。图 3-13(b) 为加热全关时 33 min 的静置记录：单通道读数波动平均 0.049 °C，通道间固定偏差的标准差为 0.19 °C。



(a) 阶梯控温实测　　(b) 校准前通道偏差

图 3-13　测温台实测

第四部分　总结

4.1 可扩展之处

QCNN 推理核和测温台都是通用的，换一套训练数据和权重即可扩展到以下任务，硬件不用改。

按点位预警。QCNN 已输出 9 路温升估计。积累更多按测点标注的数据后，可以指出是哪一段管路在升温，而不只是“沿线有异常”。

绝对温度检测。配合稳频或带温控的激光器，散斑与温度的对应关系更稳定，可在报警之外估计各段的绝对温度。

泄漏检测。冷却液泄漏会让管壁局部降温，并带来振动和形变，散斑对这些都敏感。相机最高 299 帧/s，可用帧间变化检测泄漏。

脏堵检测。冷板或支管脏堵时，下游温度缓慢升高、流量下降，可利用多点温升的时间关系识别。

整机提速。平场校正目前在 PS 上每帧约 2 s，改用分级降采样后为 41 ms，进一步移入 PL 后采集到推理可全程不经 PS；推理核 100 MHz 下仍有 2.5 ns 时序裕量，可提高时钟。

4.2 心得体会

从实测出发确定测量目标，是本作品最重要的一步。最初的方案是逐帧回归各点温度，在公开数据集上可行，但在自建测温台上，恒温时散斑几十秒就明显变化，任何模型都无法把它和温度分开。测清这一规律后，任务改为窗口化的温升报警，采集方案也随之改为锁定曝光、多帧中位数和专门的对照段。

评估协议要先于模型确定。我们一度在训练数据里混入了对照段，模型的小温升 AUC 达到 0.95 以上，把对照段也留出后降到 0.76。此后所有方法都用同一套留出划分和同一条报警规则比较，门限只用训练折的对照数据确定。

硬件与模型之间的一致性依赖统一的定点参考模型。权重、参数头文件与测试向量都由同一个脚本导出，RTL 仿真对每一层特征图逐点比对，换一套训练权重后，几分钟内就能完成回归验证。

采集链调试中，示波器之外最有效的手段是在 PL 中加入可读的状态寄存器：各 lane 的 LP 状态、同步字命中率与 ECC 统计。lane1 的故障正是通过这些计数定位到连接器的单个引脚。

4.3 大模型协作与技能包

开发全程使用大模型编程助手协作，完整交互记录（提示词、模型回答与自我纠错过程）放在仓库 report/llm_log/。协作方式是按任务拆成多个并行会话：采集链调试、数据集交接、训练、漂移分析、对比实验和报告各占一个会话，会

话之间通过共享文档和消息交接结论。

典型的自我纠错有三类：板上 DMA 读结果时进程异常退出，助手根据内核日志定位到非对齐访问，改为逐字读取；综合后权重全为 0，助手通过综合后网表仿真定位到 initial 块被忽略；漂移分析中助手发现训练集混入对照段造成的指标虚高，主动改为留出对照段重新评估。

从这些经验中提炼出四项技能包，放在仓库 skill/：定点 CNN 参考模型导出与 RTL 逐位比对流程、必须做综合后网表仿真的情形、不依赖 PYNQ 的 AXI DMA 用户态驱动、ZynqMP 上不用 libdrm 设置显示模式。每项写明适用场景、用法、失效条件和来源，都不依赖本作品的题目。

4.4 复现说明

仓库按 AMD 指南推荐的目录结构组织。复现步骤为：创建 conda 环境并拉取开源 RTL 依赖；用 Verilator 或 xsim 运行推理核、DMA 链路与显示合成的仿真，与参考结果逐位比对；用 build/vivado/build_fz3b.tcl 在 Vivado 2026.1 中重建比特流；把比特流和 src/host 下的程序拷到板上，运行 board/fz3b 中的启动脚本。各步的命令与预期输出写在 README.md 与各目录的说明中。

第五部分　参考文献

[1] Yang L, Wang X, Wu T, et al. Deep learning-based multimode fiber distributed temperature sensing[J]. Sensors, 2025, 25(9): 2811.

[2] Vélez Hoyos F J, Arango J D, Aristizábal V H, et al. Enhancing temperature sensing in fiber specklegram sensors using multi-dataset deep learning models: data scaling analysis[J]. Photonics, 2026, 13(1): 84.

[3] Gao H, Hu H F, Zhan Q W. Tailoring temperature response for a multimode fiber[J]. Opto-Electronic Science, 2025, 4(1): 240004.

[4] Redding B, Popoff S M, Cao H. All-fiber spectrometer based on speckle pattern reconstruction[J]. Optics Express, 2013, 21(5): 6584-6600.

[5] Metzger N K, Spesyvtsev R, Bruce G D, et al. Harnessing speckle for a sub-femtometre resolved broadband wavemeter and laser stabilization[J]. Nature Communications, 2017, 8: 15610.

[6] Bruce G D, O'Donnell L, Chen M, et al. Overcoming the speckle correlation limit to achieve a fiber wavemeter with attometer resolution[J]. Optics Letters, 2019, 44(6): 1367-1370.

[7] Jacob B, Kligys S, Chen B, et al. Quantization and training of neural networks for efficient integer-arithmetic-only inference[C]//IEEE CVPR. 2018: 2704-2713.

[8] Duarte J, Han S, Harris P, et al. Fast inference of deep neural networks in FPGAs for particle physics[J]. Journal of Instrumentation, 2018, 13(07): P07027.

[9] He K, Zhang X, Ren S, et al. Deep residual learning for image recognition[C]//IEEE CVPR. 2016: 770-778.

[10] Howard A, Sandler M, Chu G, et al. Searching for MobileNetV3[C]//IEEE ICCV. 2019: 1314-1324.

[11] Dosovitskiy A, Beyer L, Kolesnikov A, et al. An image is worth 16x16 words: transformers for image recognition at scale[C]//ICLR. 2021.

[12] Naug A, et al. LC-Opt: benchmarking reinforcement learning and agentic AI for end-to-end liquid cooling optimization in data centers[C]//NeurIPS Datasets and Benchmarks Track. 2025.

[13] AMD. Zynq UltraScale+ device technical reference manual (UG1085)[Z].

[14] AMD. AXI DMA LogiCORE IP product guide (PG021)[Z].

[15] MIPI Alliance. MIPI CSI-2 specification[S].

[16] OASIS. MQTT version 3.1.1[S]. 2014.

[17] Oak Ridge National Laboratory. Building an exascale-class data center[EB/OL]. (2020-12-14). https://www.olcf.ornl.gov/2020/12/14/building-an-exascale-class-data-center/.

[18] International Energy Agency. Energy and AI[R]. Paris: IEA, 2025.